

Instituto Politécnico Nacional

Escuela Superior de Ingeniería Mecánica y Eléctrica
Unidad Culhuacán

Detección y localización de manipulaciones faciales deepfakes mediante segmentación semántica basada en redes neuronales convolucionales

Presentan

Castillo Delgado Angel Ivan
Rojas Lozada Cuauhtli Emiliano

Asesores

Dr. Manuel Cedillo Hernández
Dr. Rodrigo Eduardo Arévalo Ancona

Índice

1. Estado del arte	3
1.1. A multi-label classification method combined with texture enhancement for deepfake face detection	3
1.2. Desarrollo de una aplicación Web con machine learning para la detección de Deepfakes en casos de suplantación de identidad digital	3
1.3. Deepfake Image Detection: A Review of Existing Methods and a Hybrid CNN-Based Proposed Framework	3
1.4. Digital Forensics Method for Fake Images Detection Using GAN Algorithm . . .	4
1.5. The Cat and Mouse Game: The Ongoing Arms Race Between Diffusion Models and Detection Methods	4
2. Alcances	5
3. Limites	5
4. Objetivo general	6
5. Objetivos específicos	6
6. Marco teórico	7
6.1. Manipulación facial y deepfakes	7
6.1.1. Definición operativa y tipología de manipulación facial	7
6.1.2. Imagen alterada versus región alterada: implicaciones para la formulación del problema	7
6.1.3. Alcance del sistema: restricciones operativas y delimitación del dominio .	8
6.2. Detección de deepfakes: enfoques y taxonomía	8
6.2.1. Enfoques espacial, de frecuencia y aprendizaje profundo end-to-end . . .	8
6.2.2. Enfoques híbridos y dinámica adversarial generador-detector	9
6.2.3. Generalización y degradación por postprocesamiento	9
6.3. Clasificación global vs localización	10
6.3.1. Limitaciones de la clasificación global ante manipulaciones locales	10
6.3.2. Reformulación como tarea de localización y valor forense del overlay . . .	11
6.3.3. Criterio de evaluación espacial y métricas de segmentación	11
6.4. Fundamentos de CNN para visión por computadora	12
6.4.1. Redes neuronales convolucionales	12
6.4.2. La operación de convolución	12
6.4.3. Filtros, mapas de activación y jerarquía de características	14
6.4.4. Pooling y stride	14
6.4.5. Funciones de activación	15
6.5. Segmentación semántica y formulación del problema	16
6.5.1. Artefactos e inconsistencias en deepfakes	16
6.5.2. Altas frecuencias y residuos de textura	16
6.5.3. Segmentación semántica	17
6.5.4. Formulación del problema como segmentación binaria	17
6.6. Arquitectura U-Net	17
6.6.1. Que es U-Net	17
6.6.2. Componentes principales de la arquitectura	18
6.6.3. Diferencia entre clasificación y segmentación	19
6.6.4. Variantes de U-Net	20

6.6.5.	Elección de arquitectura para el escenario de la investigación	20
6.7.	Artefactos típicos en deepfakes faciales.	20
6.7.1.	Inconsistencias de textura, bordes e iluminación como huellas forenses . .	20
6.7.2.	Señales de alta frecuencia y residuos de textura en la localización de manipulaciones	21
6.7.3.	Degradación por compresión y reescalado: implicaciones metodológicas .	22
6.8.	Datos, etiquetado y sesgos.	22
6.8.1.	Panorama de conjuntos de datos para detección de deepfakes	22
6.8.2.	Sesgos típicos y estrategia de construcción del conjunto de datos propio .	23
6.8.3.	Etiquetado de máscaras binarias y protocolo de partición	23
6.8.4.	Generalización acotada y evaluación con datos fuera del dominio de en- trenamiento	24
6.9.	Funciones de pérdida y desbalance de clases.	24
6.9.1.	Desbalance de clases en segmentación binaria de manipulaciones faciales	24
6.9.2.	Taxonomía de funciones de pérdida: distribución por píxel y solapamiento de región	25
6.9.3.	Criterio de selección: pérdidas compuestas y ponderación asimétrica . . .	25
6.10.	Métricas de evaluación para segmentación y salida forense.	26
6.10.1.	Métricas de solapamiento de región: IoU y coeficiente Dice	26
6.10.2.	Precisión, exhaustividad y definición operativa de éxito del sistema . . .	27
6.10.3.	Evaluación visual mediante overlays en el contexto forense	27
6.11.	Consideraciones forenses y operativas.	29
6.11.1.	Restricciones operativas: inferencia sin imagen de referencia y modo offline	29
6.11.2.	Salida del sistema: máscara binaria y overlay como evidencia visual . . .	29
6.11.3.	Alcances explícitos, limitaciones declaradas y casos difíciles	30
6.11.4.	Conexión del marco teórico con las decisiones metodológicas	30

1. Estado del arte

1.1. A multi-label classification method combined with texture enhancement for deepfake face detection

Los autores Deng et al. [2025] proponen el modelo Q2L-DeepFake, el cual busca extender la detección tradicional binaria hacia una clasificación multi-etiqueta para identificar manipulaciones en zonas específicas del rostro. La arquitectura utiliza una CNN (ResNet101) con un módulo enfocado a mejorar las texturas para identificar detalles sutiles en capas superficiales, la cual se conecta a un Transformer Decoder encargado de realizar la detección de falsificaciones mediante las etiquetas mencionadas. Finalmente, integran la función de pérdida APL (Asymmetric Polynomial Loss) para manejar el desequilibrio entre clases y el balance de los datos. Para la fase de entrenamiento Los autores mencionan la limitante que tuvieron debido a que los datos están pensados más en la clasificación binaria por lo que utilizaron el data set Seq-Deepfake aplicando un pre-procesamiento para redefinir las etiquetas características del rostro dividiéndolas en 5 categorías: cejas, nariz, labios, ojos y cabello. Con esto, lograron habilitar el aprendizaje multi-etiqueta, ampliando el nivel de distinción del modelo. De igual forma el estudio fundamenta la inclusión de un modelo de mejora de texturas es necesaria debido a que los rastros de falsificación son en su mayoría imperceptibles y se encuentran comúnmente en las frecuencias altas y la información de textura de la imagen, su modelo actúa en las capas superficiales para extraer y amplificar residuos de textura antes que la red abstraiga la información.

1.2. Desarrollo de una aplicación Web con machine learning para la detección de Deepfakes en casos de suplantación de identidad digital

El autor Yagual Castillo [2024] utiliza técnicas de Machine Learning para mitigar los riesgos de la suplantación de identidad digital causada por los Deepfakes. Su propuesta se desarrolla una aplicación web diseñada para asegurar la seguridad digital, permitiendo que usuarios sin un conocimiento previo o especializado puedan analizar imágenes (en formatos como JPG, PNG o TIFF) para confirmar su veracidad.

El autor entrena un modelo mediante TensorFlow y Keras, empleando una Red Neuronal Convolutiva (CNN). Esta arquitectura es utilizada para procesar la retícula de la imagen y extraer características faciales complejas, permitiendo al sistema identificar inconsistencias imperceptibles para el ojo humano. El modelo final aplica una clasificación binaria tradicional, priorizando la accesibilidad y la prevención del fraude sobre la complejidad arquitectónica.”

1.3. Deepfake Image Detection: A Review of Existing Methods and a Hybrid CNN-Based Proposed Framework

En esta investigación, los autores Tiwari and Patil [2025] realizan una revisión crítica de las limitantes actuales en la detección de Deepfakes, destacando problemas como el sesgo en los conjuntos de datos y la falta de generalización en escenarios reales. Para mitigar estas deficiencias, proponen una arquitectura híbrida basada en CNN que integra ResNet-50 (enfocada en bloques residuales) para una extracción robusta de características profundas, conectada a una red VGG-16 que actúa como clasificador especializado.

Emplean pesos pre-entrenados de ImageNet para ambas redes y diseñan una estrategia de entrenamiento en dos fases: primero, congelan las capas inferiores de VGG-16 (que detectan

patrones visuales simples como bordes) para ajustar solo las capas superiores utilizando las características extraídas por ResNet; posteriormente, realizan un ajuste fino (fine-tuning) selectivo en las capas superiores de ResNet-50 junto con el clasificador para especializar el sistema en la detección de artefactos de manipulación. Este enfoque, validado sobre los conjuntos de datos Celeb-DF y DFDC, busca equilibrar la capacidad de extracción de características locales profundas con una clasificación más eficiente, priorizando la robustez frente a post-procesamientos comunes como la compresión y la redimensión.

1.4. Digital Forensics Method for Fake Images Detection Using GAN Algorithm

Los autores Mashhadani et al. [2025] presentan un método de detección usando técnicas forenses basado en marcas de agua y contenido de imágenes falsas generadas con GAN, específicamente usando StyleGAN2-ADA. Se propone un flujo donde se toman imágenes, se redimensiona a 256 x 256 píxeles y se les inserta texto invisible de 5,000 caracteres mediante dos técnicas, bit menos significativo y transformada discreta del coseno, luego esas imágenes con marca de agua se utilizan como insumo para generar imágenes sintéticas con StyleGAN2-ADA en un entorno tipo Google Colab con GPU.

Se evalúan el impacto de las marcas de agua, la efectividad para detectar falsificación al extraer el texto oculto, reportando que el texto extraído desde las imágenes falsas se vuelve inentendible porque StyleGAN2-ADA altera el contenido, finalmente, se entrena un modelo de aprendizaje profundo basado en capas de convolución para clasificar imágenes como reales o falsas; los autores describen una arquitectura de varias capas y mencionan el uso de transformaciones de entrenamiento para mejorar la capacidad de generalizar.

Los autores refuerza la pertinencia de pasar de una decisión global (real/falso) a una localización espacial mediante máscara, además, al remarcar que ciertos enfoques requieren la imagen original y que, en su ausencia, disminuye la precisión, indica que un sistema debería de operar sin referencia, apoyándose en huellas internas del contenido.

1.5. The Cat and Mouse Game: The Ongoing Arms Race Between Diffusion Models and Detection Methods

Los autores Laurier et al. [2024] presentan una revisión sobre la carrera armamentista entre la generación de imágenes mediante modelos de difusión y las técnicas de detección, y organizan el campo mediante una taxonomía de enfoques: análisis en dominio de frecuencia (p. ej., métodos basados en Fourier y en wavelets), análisis en dominio espacial (estadísticas locales, patrones de ruido y artefactos a nivel píxel), métodos de detección basados en aprendizaje profundo (redes convolucionales, transformadores de visión y detectores multimodales) y enfoques híbridos que combinan señales espaciales y frecuenciales; además, incorporan el rol de conjuntos de datos y bancos de prueba, así como implicaciones y aplicaciones relacionadas con desinformación, derechos de autor y análisis forense.

Se discuten desafíos centrales que explican por qué la detección es un problema en evolución constante: los detectores suelen fallar al generalizar entre distintos modelos de difusión por la presencia de huellas específicas de cada generador, y también pierden desempeño ante transformaciones comunes en escenarios reales como compresión y redimensionamiento; adicionalmente, se subraya el caso de contenido mixto (elementos reales y sintéticos dentro de una misma imagen, como en tareas de relleno o secciones manipuladas), donde métodos globales pueden pasar por alto alteraciones locales y se requiere evaluar y diseñar métodos con capacidad de operar a nivel más fino, apoyados por conjuntos de datos más diversos que contemplen condiciones de uso real y protocolos de evaluación comparables.

Los autores señalan que en imágenes con contenido real y sintético mezclado es necesario distinguir componentes reales y generados dentro de la misma imagen, y proponen que esto se evalúe a nivel píxel, además de mencionar que se investigan técnicas de localización con supervisión débil para abordar este escenario; también enfatizan que los detectores deben ser robustos a compresión y reescalado (degradaciones comunes en redes sociales) y capaces de generalizar a modelos no vistos.

2. Alcances

- El proyecto se enfoca exclusivamente al análisis del rostro. El modelo se entrenará para detectar inconsistencias en texturas, iluminación y bordes dentro del contexto facial.
- Salida de segmentación explicativa: se entrega una máscara binaria (alterado/no alterado) y una visualización (overlay) que resalta la región modificada; se busca una región aproximada (no necesariamente precisión extrema sobre los píxeles modificados, mas bien un acotamiento próximo de segmentación)
- Manipulaciones cubiertas (deepfake): se considera remplazo de rostros, recreación y generación completa, incluyendo escenarios donde se agrega un rostro adicional en el encuadre.
- Sin imagen de referencia en inferencia: el sistema estará diseñado para segmentar con una sola imagen, sin requerir comparación contra una “foto real” de la persona.
- Conjunto de datos propio: recopilación, curación y estandarización de un conjunto de datos y banco de pruebas con meta de 50,000 muestras, con variación de contexto, con partición entrenamiento/validación/prueba y etiquetado mediante máscara binaria (alterado/no alterado) limitada a la región facial para las manipulaciones cubiertas.

3. Límites

- Debido a la carga computacional que implica el uso del modelo U-Net como un segmentador y la complejidad de su arquitectura compuesta por varias capas convolucionales el sistema no está diseñado para procesamiento en tiempo real en dispositivos de borde (móviles/IoT), sino para análisis forense offline o en servidores con GPU dedicada.
- El desempeño del segmentador U-Net y la posterior detección pueden verse afectados significativamente en imágenes con baja resolución, compresión excesiva o condiciones de iluminación extrema (muy oscura o saturada), donde los artefactos de compresión pueden confundirse con artefactos de manipulación
- Validez condicionada al conjunto de entrenamiento: el desempeño del modelo depende de los contextos y condiciones representados en el dataset; puede degradarse en escenarios subrepresentados, especialmente cuando el rostro sea muy pequeño, parcialmente visible u ocurra en encuadres complejos.
- Generalización acotada a técnicas conocidas: el rendimiento puede degradarse frente a métodos de deepfake no representados durante el entrenamiento.
- Segmentación limitada al rostro: la detección se restringe a la región facial; no se promete localizar manipulación en cabello, cuello, cuerpo o fondo.

- Sin clasificación del tipo de manipulación: el sistema no identifica qué tipo de deepfake es; entrega únicamente máscara binaria y resaltado.
- Casos difíciles no garantizados: oclusión fuerte (mano, cubre bocas, lentes), movimiento, baja luz extrema, compresión severa o elementos sobrepuestos pueden aumentar falsos positivos o falsos negativos.

4. Objetivo general

Desarrollar una red neuronal para la detección y localización de manipulaciones faciales (deepfakes) mediante un modelo de segmentación semántica basado en redes neuronales convolucionales (arquitectura U-Net), orientado al análisis forense de imágenes.

5. Objetivos específicos

- Recopilar un conjunto de datos (dataset) conformado por 50,000 muestras, estandarizando las imágenes para incluir variaciones de contexto y etiquetado mediante máscaras binarias enfocado a deepfakes que delimiten exclusivamente la región facial manipulada.
- Diseñar e implementar una arquitectura basada en U-Net optimizada para la detección de inconsistencias en texturas, iluminación y bordes, capaz de generar una salida de segmentación.
- Entrenar y validar el modelo utilizando el dataset recopilado, enfocándose en la generalización frente a técnicas de reemplazo, recreación y generación de rostros, considerando las limitaciones de carga computacional para un entorno de análisis offline.
- Evaluar el desempeño del sistema mediante métricas de segmentación, generando visualizaciones (overlays) que resalten las regiones modificadas para facilitar la interpretación forense de los resultados.

6. Marco teórico

6.1. Manipulación facial y deepfakes

6.1.1. Definición operativa y tipología de manipulación facial

Los autores Mirsky and Lee [2021], describen los deepfakes como contenido multimedia sintético o manipulado mediante técnicas de inteligencia artificial, donde la verosimilitud visual se logra por modelos generativos capaces de reproducir rasgos faciales, texturas y patrones de iluminación con alta fidelidad. En el ámbito de visión por computadora, el término se utiliza de forma operativa para referirse a manipulaciones que alteran la identidad aparente o la dinámica facial de una persona, con o sin una fuente real de referencia, y que pueden integrarse a flujos de edición que ocultan rastros evidentes mediante posprocesamiento, por ejemplo, compresión y re-escalado. Mirsky and Lee [2021], Murguía Serrano et al. [2025a]

En particular, la manipulación facial puede organizarse como un conjunto de transformaciones sobre el rostro que abarcan:

- Reemplazo de rostro (intercambio de identidad)
- Recreación o reenactment (conducción de expresiones o movimientos faciales de un sujeto por las señales de otro)
- Edición (modificaciones localizadas del rostro sin sustituir por completo la identidad)
- Síntesis (generación de un rostro completo sin un objetivo real como base).

Esta clasificación es importante porque describe que se espera encontrar: el reemplazo y la recreación tienden a introducir discontinuidades en contornos y coherencias internas del rostro, mientras que la síntesis puede producir coherencias globales altas, pero inconsistencias de textura en regiones específicas. Murguía Serrano et al. [2025a]

Los flujos de generación y edición de rostros suelen incluir etapas de detección y alineación facial, extracción de representaciones (por ejemplo, puntos faciales o descriptores aprendidos), generación mediante modelos como redes generativas antagónicas (GAN) o modelos de difusión, y finalmente una fase de mezclado y posprocesamiento para integrar el rostro manipulado con el contexto (color, grano, compresión y bordes). La bibliografía indica que estas etapas no solo producen una “imagen falsa”, sino que también pueden dejar huellas residuales de naturaleza local (texturas, microbordes, patrones de ruido o inconsistencias de iluminación) que son el objetivo de los detectores modernos. Hu et al. [2024], Murguía Serrano et al. [2025a]

6.1.2. Imagen alterada versus región alterada: implicaciones para la formulación del problema

Una distinción clave para fines forenses es separar el caso de imagen alterada (una decisión global real/falsa) del caso de región alterada (alteración parcial dentro de la misma imagen). En escenarios reales, una manipulación puede afectar solo ciertas zonas del rostro y, además, las huellas pueden aparecer de forma no uniforme o en ubicaciones variables; por lo que hay una necesidad de detectar y localizar las áreas manipuladas, ya que la clasificación global puede pasar por alto alteraciones pequeñas o mezcladas con contenido real. Esta diferencia es especialmente importante cuando se busca producir evidencia visual verificable y no solo una etiqueta. Hu et al. [2024]

6.1.3. Alcance del sistema: restricciones operativas y delimitación del dominio

Con base en el planteamiento del proyecto, se adopta una definición operativa de deepfake enfocada en manipulaciones faciales en imagen fija, incluyendo reemplazo de rostro, recreación facial, generación completa del rostro y casos donde aparece un rostro adicional o alteraciones parciales dentro del área facial. Asimismo, el objetivo no se limita a dictaminar autenticidad, sino a producir una máscara binaria y una visualización de la región aproximada manipulada, acotada a la zona del rostro, lo que convierte el problema en uno de localización/segmentación y no únicamente de clasificación. En términos de restricciones operativas, la red se concibe para funcionar sin imagen de referencia (es decir, sin disponer del "original" para comparar), lo que obliga a basar la decisión en inconsistencias internas del contenido y en patrones aprendidos a partir de datos etiquetados. Esta condición es coherente con el uso forense en el que suele existir únicamente la evidencia disponible (una imagen) y se requiere acompañar la decisión con una explicación visual. Finalmente, aunque existen enfoques multimodales que integran señales de imagen, audio y video para ampliar la cobertura del problema, el alcance de este trabajo se centra en imagen fija y en el rostro como región de interés principal. Esta delimitación permite formalizar con mayor claridad el espacio de búsqueda (píxeles faciales) y los productos esperados del sistema (máscara y evidencia visual), preparando el terreno conceptual para la formulación de segmentación semántica.

6.2. Detección de deepfakes: enfoques y taxonomía

6.2.1. Enfoques espacial, de frecuencia y aprendizaje profundo end-to-end

La detección de deepfakes se ha consolidado como un problema central del análisis forense digital debido a la rápida evolución de los generadores y a la creciente dificultad para distinguir contenido real de contenido sintético bajo condiciones de despliegue reales. En este contexto, el propósito del presente apartado es ubicar la propuesta de esta tesis dentro del panorama del campo, identificando las familias de métodos dominantes, las señales que buscan explotar y las limitaciones estructurales que condicionan su vigencia, con especial énfasis en la generalización y en la degradación introducida por compresión y reescalado.

De forma operativa, la bibliografía organiza los enfoques de detección en función del tipo de evidencia que se modela y del espacio donde se manifiestan las huellas. En este trabajo se adopta una taxonomía de cuatro enfoques de alto nivel:

- Enfoque espacial.
- Enfoque en frecuencia.
- Enfoque basado en aprendizaje profundo (end-to-end).
- Enfoques híbridos.

Esta organización no pretende ser excluyente, ya que diversos modelos contemporáneos combinan señales y representaciones; sin embargo, permite sintetizar la intuición forense detrás de cada familia y, en consecuencia, discutir sus fallas típicas ante el cambio de dominio (conjunto de datos, generador y postprocesado) Banerjee et al. [2025], Murguía Serrano et al. [2025a].

En el enfoque espacial, la detección se apoya en inconsistencias observables en el dominio de píxel, es decir, irregularidades locales o globales que emergen del mezclado, la edición y la síntesis facial. Típicamente se buscan discontinuidades en contornos, incoherencias en iluminación, texturas atípicas, patrones de ruido residuales o discrepancias entre la región facial y su contexto. En implementaciones modernas, estas señales se capturan mediante extractores aprendidos (p. ej., CNN), que identifican patrones discriminativos asociados a manipulaciones

y, en variantes orientadas a localización, habilitan mapas de activación o máscaras que aproximan la región alterada. No obstante, al depender de huellas que pueden ser atenuadas por posprocesamiento, su desempeño suele degradarse en escenarios con compresión, baja resolución u oclusiones, además de mostrar sensibilidad a sesgos de captura y a variaciones de escena. Alrashoud [2025], Banerjee et al. [2025]

En el enfoque de frecuencia, la hipótesis es que los procesos de generación introducen artefactos espectrales que no son necesariamente evidentes en el espacio de píxel, pero sí se manifiestan como anomalías en bandas de alta frecuencia o como distribuciones espectrales atípicas. Parte de la evidencia reportada en la bibliografía vincula estas huellas con operaciones internas de los generadores, por ejemplo, etapas de sobremuestreo en arquitecturas GAN, que dejan patrones característicos en el espectro. En consecuencia, se utilizan transformadas (p. ej., Fourier, DCT o wavelets) y descriptores espectrales para separar contenido real de contenido sintético. Sin embargo, una limitación crítica es que dichas huellas pueden variar entre generadores y, por tanto, inducir sobreajuste a patrones específicos del modelo de síntesis o del dominio de entrenamiento, reduciendo la capacidad de generalización a fuentes no vistas. Tan et al. [2024]

El enfoque basado en aprendizaje profundo, entendido como detección end-to-end, agrupa estrategias donde el modelo aprende representaciones discriminativas directamente de los datos, sin depender explícitamente de un conjunto fijo de rasgos forenses diseñados a mano. En esta familia se incluyen arquitecturas CNN y variantes con mecanismos de atención o módulos complementarios, entrenadas en clasificación (real/falso) o en formulaciones que incorporan supervisión espacial cuando se dispone de anotaciones. Su ventaja práctica es la capacidad de modelar patrones complejos y no lineales; sin embargo, la bibliografía coincide en que el rendimiento reportado en pruebas intra-dataset no necesariamente se sostiene en evaluación cruzada de datos, donde se presentan técnicas de falsificación no vistas, cambios de dominio y distribución distinta a la del entrenamiento. En este sentido, la generalización se reconoce como un problema crítico, debido a la tendencia de muchos detectores a capturar correlaciones espurias o "huellas" específicas del generador, más que indicios robustos y transferibles. Li et al. [2025a], Yang et al. [2025]

6.2.2. Enfoques híbridos y dinámica adversarial generador-detector

Los enfoques híbridos surgen como respuesta directa a la fragilidad de un único tipo de evidencia. De manera general, un enfoque híbrido integra representaciones espaciales y espectrales, o combina señales forenses (p. ej., inconsistencias de compresión o residuales) con características aprendidas por redes profundas, mediante arquitecturas multirrama y mecanismos de fusión. La intuición es que la manipulación deja rastros en múltiples niveles: algunos son locales en el píxel, otros se expresan como firmas en frecuencia y otros se manifiestan como discrepancias de coherencia global; por lo tanto, la combinación explícita puede aumentar sensibilidad y robustez ante variaciones. En la bibliografía reciente se observa un énfasis en modelar interacciones espacio-frecuencia y en diseñar estrategias orientadas a mejorar la generalización, precisamente porque los artefactos aislados tienden a perder estabilidad frente a generadores nuevos y frente a interferencia por postprocesado. Li et al. [2025a], Qiao et al. [2025]

6.2.3. Generalización y degradación por postprocesamiento

El fenómeno de "gato y ratón" entre generadores y detectores describe una dinámica adversarial: a medida que los modelos de síntesis incrementan realismo y reducen artefactos visibles, los detectores deben migrar hacia señales más sutiles o hacia estrategias de entrenamiento que no dependan de firmas específicas. En consecuencia, un detector entrenado sobre una familia

de manipulaciones puede experimentar degradación notable al enfrentarse a falsificaciones no vistas, lo cual limita la vigencia práctica de métodos altamente especializados. Esta dinámica también se relaciona con la necesidad de protocolos de evaluación más representativos y con el uso de bancos de prueba estandarizados que reflejen condiciones reales de circulación de contenido, donde cambian estilos, fuentes y procesos de compresión y reempaquetado. Alrashoud [2025], Chandra et al. [2025], Qiao et al. [2025]

En este marco, la generalización se entiende como la capacidad del detector para mantener desempeño ante cambios de dominio: nuevos generadores, nuevas distribuciones de datos y nuevas condiciones de captura y publicación. La evidencia reciente subraya que, incluso cuando los modelos obtienen resultados altos en conjuntos académicos, su desempeño puede caer de forma pronunciada en datos *in-the-wild*, recolectados de plataformas y escenarios contemporáneos. Adicionalmente, la compresión, el reescalado y otros posprocesos actúan como perturbaciones que suprimen o distorsionan huellas forenses, afectando tanto señales espaciales (pérdida de microtextura) como señales espectrales (alteración de distribuciones de frecuencia). Por ello, la delimitación del problema hacia la localización/segmentación en la región facial de interés y la producción de evidencia visual (máscara y overlay) se alinean con la necesidad de ofrecer una salida verificable, aun cuando la decisión de clasificación global sea insuficiente en escenarios de alteración parcial. Chandra et al. [2025], Hu et al. [2024], Li et al. [2025a]

6.3. Clasificación global vs localización

6.3.1. Limitaciones de la clasificación global ante manipulaciones locales

La detección de deepfakes puede abordarse como un problema de clasificación global, en el cual el modelo asigna una etiqueta binaria (real/falso) a la imagen completa. En este enfoque, la red neuronal aprende correlaciones estadísticas globales que distinguen imágenes auténticas de manipuladas. Si bien esta formulación resulta útil cuando la alteración afecta gran parte del contenido visual, presenta limitaciones importantes en escenarios reales, donde las manipulaciones suelen ser locales o parciales.

En la práctica, muchas falsificaciones digitales modifican únicamente regiones específicas del rostro —por ejemplo, ojos, boca o contornos faciales— mediante técnicas de reemplazo, reenactment o blending. Cuando la alteración está espacialmente restringida, los modelos de clasificación global pueden no detectar señales suficientemente discriminativas, especialmente después de procesos de post-compresión o suavizado que reducen los artefactos visibles. Esto puede derivar en falsos negativos, ya que la imagen conserva gran parte de su estadística global intacta.



Figura 1: Ejemplos de manipulaciones faciales empleadas en la generación de deepfakes. Se observan técnicas como reemplazo de rostro (DeepFakes, FaceSwap), reenactment (Face2Face) y restauración (Face Restoration, Neural Textures). Estas alteraciones suelen concentrarse en áreas localizadas (ojos, boca, contornos), lo que justifica el uso de métodos de segmentación en lugar de clasificación global.

6.3.2. Reformulación como tarea de localización y valor forense del overlay

Por esta razón, el problema abordado en esta tesis se reformula como una tarea de localización de manipulación, donde el objetivo no es únicamente determinar si una imagen es falsa, sino identificar qué regiones han sido alteradas. En lugar de producir una etiqueta escalar, el modelo genera un mapa espacial o máscara que asigna a cada píxel una probabilidad de pertenecer a una zona manipulada. Esta formulación corresponde al paradigma de segmentación semántica, que permite modelar explícitamente la estructura espacial de la falsificación.

La generación de una máscara (overlay) aporta además un valor técnico y forense significativo: proporciona evidencia visual interpretable, permite cuantificar la extensión de la manipulación (porcentaje de píxeles afectados) y facilita análisis posteriores centrados exclusivamente en las regiones sospechosas. En contraste, una decisión global carece de información explicativa sobre la naturaleza o ubicación de la alteración.




Figura 2: Arquitectura de red neuronal convolucional para localización de manipulaciones. La imagen de entrada se procesa mediante capas convolucionales (Conv Layer 1-5) que extraen características multiescala. Luego, bloques LSTM modelan dependencias espaciales y finalmente se genera una máscara binaria (manipulated mask) que identifica las regiones alteradas a nivel de píxel. Este enfoque permite no solo detectar la falsificación, sino también delimitar su extensión espacial.

6.3.3. Criterio de evaluación espacial y métricas de segmentación

Diversos trabajos como los estudios basados en el dataset FaceForensics++, muestran que los detectores globales pueden mantener un buen desempeño en escenarios controlados, pero pierden robustez frente a manipulaciones localizadas, contenido mixto o degradaciones introducidas por compresión Rössler et al. [2019]. En consecuencia, investigaciones recientes incorporan explícitamente tareas de localización y generación de mapas de manipulación como parte fundamental del análisis forense automatizado. Bappy et al. [2017]

Bajo esta perspectiva, la presente investigación adopta un enfoque de segmentación pixel-a-pixel, donde la precisión del modelo se evalúa mediante métricas espaciales como la intersección sobre unión (IoU) y el coeficiente Dice, las cuales miden el grado de coincidencia entre la región predicha y la región real manipulada Jaccard [1912]. Este criterio permite cuantificar de manera objetiva la capacidad del sistema no solo para detectar la falsificación, sino para delimitarla con precisión espacial.

6.4. Fundamentos de CNN para visión por computadora

6.4.1. Redes neuronales convolucionales

Los autores describen las redes neuronales convolucionales como un tipo de red neuronal especializada en el procesamiento de datos que tiene una topología conocida similar a una cuadrícula. Mencionan particularmente a las imágenes las cuales pueden considerarse como una cuadrícula bidimensional de píxeles. El nombre red neuronal convolucional indica que la red emplea una operación matemática llamada convolución. La convolución es un tipo especializado de operación lineal. Por su parte las redes neuronales convolucionales son simplemente redes neuronales que utilizan la convolución en lugar de la multiplicación matricial general en al menos una de sus capas.

6.4.2. La operación de convolución

La operación de convolución se define como una operación matemática entre dos funciones que produce una tercera función que representa la cantidad de superposición entre ellas. En términos continuos puede expresarse como:

$$s(t) = \int x(a)w(t-a)da$$

Esta operación se denomina convolución y normalmente se indica con un asterisco

$$s(t) = (x * w)(t)$$

Donde:

- x representa la señal de entrada o los datos originales. En el contexto de las redes neuronales convolucionales, esta señal corresponde a los valores de los píxeles de una imagen
- w representa el filtro o kernel de convolución en el contexto de CNN el cual es una matriz de valores que se utilizan para detectar características específicas en la imagen (Bordes, texturas, patrones, etc.)
- $*$ representa la operación de convolución entre la señal de entrada x y el filtro w
- t representa la posición o desplazamiento en la señal o imagen donde se está aplicando el filtro
- $s(t)$ es el resultado de la convolución, es decir, una señal nueva resultante del proceso de convolución o un mapa de activación en el contexto de las CNN obtenido después de aplicar un filtro a una señal de entrada.

En el contexto de redes neuronales convolucionales, esta operación se utiliza para aplicar filtros sobre imágenes con el objetivo de detectar patrones locales como bordes, texturas o formas. Cada filtro se desplaza sobre la imagen generando mapas de activación que resaltan dichas características.

Sin embargo, en aplicaciones de aprendizaje automático y visión por computadora, los datos utilizados no son continuos sino discretos. Las imágenes digitales, por ejemplo, se representan como matrices de valores numéricos correspondientes a píxeles. Debido a esto, la operación de convolución se expresa mediante una forma discreta, en la cual la integral es reemplazada por una suma.

$$s(t) = \sum_a x(a)w(t-a)$$

Donde:

- $x(a)$ representa la señal de entrada en la posición a
- $w(t-a)$ valor del filtro desplazado
- a representa el índice discreto de la suma
- $s(t)$ es el resultado de la convolución en la posición t

Debido a que las imágenes digitales se pueden representar como matrices bidimensionales de píxeles, para llevar a cabo el proceso de convolución se aplica la misma fórmula, pero adaptada a 2 dimensiones:

$$s(i,j) = \sum_m \sum_n x(i-m, j-n)w(m,n)$$

Donde:

- $x(i,j)$ es el valor del píxel en la imagen de entrada.
- $w(m,n)$ es el valor del filtro o kernel.
- $s(i,j)$ es el resultado de la convolución en la posición (i,j) .
- m,n son los Índices del kernel.




Figura 3: Ejemplo de un proceso de convolución en una matriz de 2 dimensiones y el proceso para generar cada uno de los elementos (tensores) que componen el mapa de activación resultante después de aplicar el filtro en la matriz de entrada

Aunque el término convolución es ampliamente utilizado en redes neuronales convolucionales, en la práctica la operación implementada en la mayoría de los frameworks de aprendizaje profundo corresponde técnicamente a una correlación cruzada (cross-correlation). La principal diferencia entre ambas operaciones radica en que la convolución implica una inversión del filtro

antes de realizar el desplazamiento sobre la señal de entrada, mientras que en la correlación el filtro se aplica directamente sin dicha inversión. A pesar de esta diferencia matemática, en el contexto del aprendizaje profundo ambos términos suelen utilizarse de manera intercambiable, ya que los filtros son aprendidos automáticamente durante el entrenamiento de la red.

6.4.3. Filtros, mapas de activación y jerarquía de características

En las redes neuronales convolucionales, los filtros o kernels son pequeñas matrices de valores que se utilizan para detectar características específicas dentro de una imagen. Estos filtros se desplazan sobre la matriz de entrada aplicando la operación de convolución o correlación en cada posición. Durante el proceso de entrenamiento, los valores de los filtros se ajustan automáticamente mediante algoritmos de optimización, permitiendo que la red aprenda a identificar patrones relevantes en los datos.

El resultado de aplicar un filtro sobre una imagen de entrada se denomina mapa de activación (feature map). Este mapa representa la respuesta del filtro en cada posición de la imagen, resaltando aquellas regiones donde el patrón detectado por el filtro está presente. Cada filtro genera un mapa de activación diferente, lo que permite a la red neuronal capturar múltiples características visuales dentro de la imagen.

Las redes neuronales convolucionales aprenden una jerarquía de características visuales a través de sus diferentes capas. En las primeras capas, los filtros suelen detectar características simples como bordes y orientaciones. En capas intermedias, la red comienza a identificar patrones más complejos como texturas o formas. Finalmente, en las capas más profundas se reconocen estructuras de mayor nivel, como partes de objetos o configuraciones faciales completas. Esta capacidad de aprender representaciones jerárquicas permite a las CNN analizar imágenes de forma eficiente en tareas de reconocimiento y clasificación. Esta capacidad de las redes neuronales convolucionales para aprender representaciones jerárquicas resulta especialmente útil en tareas como la detección de deepfakes, ya que permite identificar inconsistencias visuales sutiles presentes en imágenes manipuladas, tales como anomalías en texturas faciales, iluminación o patrones de compresión.

En las redes neuronales convolucionales, esta operación se aplica repetidamente a través de múltiples capas convolucionales. Cada capa utiliza varios filtros que son aprendidos automáticamente durante el proceso de entrenamiento, permitiendo a la red detectar diferentes tipos de características visuales. Como resultado, se generan múltiples mapas de activación que capturan patrones relevantes dentro de la imagen de entrada.

6.4.4. Pooling y stride

En las redes neuronales convolucionales, el pooling es una operación mediante la cual se busca reducir la dimensionalidad o tamaño de los mapas de activación generados por las capas convolucionales. Esta reducción permite disminuir el número de parámetros que utiliza el modelo y el costo computacional hablando de recursos, al mismo tiempo se conserva la información que es de mayor relevancia para las características que previamente fueron detectadas. Este proceso consiste en dividir el mapa de activación en pequeñas regiones y aplicar una función de agregación sobre cada una de ellas dando como resultado un mapa de activación mas pequeño pero que conserva las características mas importantes detectadas por los filtros de la red.

El max pooling es uno de los métodos de pooling más utilizados en redes neuronales convolucionales. En este método, para cada región del mapa de activación se selecciona únicamente el valor máximo. De esta manera, se conserva la característica más significativa detectada por el filtro en esa región específica. Este mecanismo permite que la red neuronal mantenga las activaciones más relevantes y reduzca la información redundante, lo que contribuye a mejorar la eficiencia del modelo.

Otro método utilizado es el average pooling, el cual calcula el valor promedio dentro de cada región del mapa de activación. Aunque este método también reduce la dimensionalidad de los datos, en la práctica el max pooling suele utilizarse con mayor frecuencia en arquitecturas modernas de redes neuronales convolucionales debido a su mejor desempeño en muchas tareas de visión por computadora.

En la operación de convolución, el stride (comúnmente traducido como paso o zancada) es un hiperparámetro estructural que determina la cantidad de unidades espaciales o píxeles que el filtro (kernel) avanza sobre la matriz de entrada en cada iteración. En las operaciones de convolución estándar, se asume un desplazamiento unitario (stride = 1), lo que significa que el filtro se mueve un píxel a la vez de izquierda a derecha y de arriba hacia abajo, procesando la imagen de manera altamente superpuesta. Sin embargo, al incrementar este valor (por ejemplo, un stride de 2), el filtro "salta" posiciones, desplazándose de dos en dos píxeles. El impacto principal del stride se ve reflejado en las dimensiones espaciales del mapa de activación resultante una vez terminado el proceso de convolución, si el stride es grande, las dimensiones serán menores actuando como un mecanismo de submuestreo y se denota de la siguiente manera:

$$O = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$

Donde:

- O representa la dimensión espacial del mapa de activación de salida
- W es la dimensión de la imagen o matriz de entrada
- K es el tamaño del filtro o kernel
- P representa el padding (relleno) aplicado a los bordes de la entrada
- S es el valor del stride o desplazamiento.

6.4.5. Funciones de activación

En las redes neuronales convolucionales, después de realizar la operación de convolución se aplica una función de activación. Estas funciones introducen no linealidad en el modelo, lo cual permite que la red neuronal pueda aprender representaciones más complejas de los datos. Sin la incorporación de funciones no lineales, una red compuesta únicamente por operaciones lineales sería equivalente a una sola transformación lineal, limitando significativamente su capacidad de aprendizaje. Las funciones de activación se aplican a los valores generados por las capas convolucionales, produciendo mapas de activación que posteriormente son procesados por las siguientes capas de la red. De acuerdo con Goodfellow et al. [2016], las funciones de activación permiten que las redes neuronales profundas modelen relaciones complejas presentes en los datos y facilitan el aprendizaje de representaciones jerárquicas en tareas de visión por computadora.

Una de las funciones de activación más utilizadas en redes neuronales convolucionales es la Rectified Linear Unit (ReLU). Esta función se caracteriza por su simplicidad y eficiencia

computacional, ya que transforma los valores negativos en cero y mantiene los valores positivos sin modificación.

La función ReLU puede definirse como:

$$f(x) = \max(0, x)$$

Donde:

- x representa el valor de entrada proveniente de la capa convolucional
- $f(x)$ corresponde al valor resultante después de aplicar la función de activación.

Según lo descrito por Goodfellow et al. [2016], el uso de la función ReLU facilita el entrenamiento de redes neuronales profundas, ya que ayuda a reducir el problema del gradiente desvanecido y permite una convergencia más rápida durante el proceso de aprendizaje.

6.5. Segmentación semántica y formulación del problema

6.5.1. Artefactos e inconsistencias en deepfakes

La generación de deepfakes mediante modelos de aprendizaje profundo, específicamente las redes generativas adversarias (GAN) y autoencoders ha permitido que se genere una amplia gama de videos o imagenes altamente realistas.

Sin embargo, a pesar de los avances en estos métodos de generación, las manipulaciones digitales suelen presentar artefactos visuales o inconsistencias que pueden ser detectadas mediante técnicas de visión por computadora. Investigaciones como FaceForensics++: Learning to Detect Manipulated Facial Images de Andreas Rossler han demostrado que las regiones manipuladas en deepfakes constantemente contienen irregularidades en aspectos como la textura de la piel, los bordes faciales, la iluminación y las sombras.

En el contexto facial y corporal los artefactos mas comunes se encuentran las texturas con inconsistencias que se puede identificar por un suavizado excesivo en la piel o perdida en detalles pequeños que normalmente forman parte de la piel o el rostro en si. Estas anomalías surgen en el momento en el que el modelo que genera dichas alteraciones prioriza la coherencia general de la imagen antes que los detalles más finos lo que provoca que surgen detalles como los anteriormente mencionados o bordes irregulares o transiciones abruptas entre el rostro alterado y el resto de la imagen, una de las zonas que se ve mayormente afectada por esto es el cabello o el contorno facial.

Otro tipo de inconsistencia constante es las sombras o la iluminación incoherente en donde las condiciones de dichas características no coinciden con las del entorno global en la imagen. Estas características pueden ser explotadas por algoritmos diseñados para la detección automática.

6.5.2. Altas frecuencias y residuos de textura

Un aspecto relevante en la detección de manipulaciones faciales es el análisis de componentes de alta frecuencia presentes en la imagen. Las altas frecuencias contienen información asociada a bordes, microtexturas y detalles finos, los cuales suelen alterarse durante el proceso de generación o compresión de deepfakes. Métodos como el propuesto en MesoNet: a Compact Facial Video Forgery Detection Network de Darius Afchar demuestran que los detectores de deepfakes pueden aprovechar estos residuos de textura para identificar patrones característicos de manipulación. En muchos casos, las regiones generadas presentan distribuciones de frecuencia distintas a las de imágenes reales, lo que permite detectar anomalías incluso cuando las alteraciones no son fácilmente perceptibles para el ojo humano.

6.5.3. Segmentación semántica

Para identificar estas regiones manipuladas, es posible emplear técnicas de segmentación semántica, una tarea de visión por computadora que consiste en asignar una etiqueta a cada píxel de una imagen. A diferencia de los métodos de clasificación de imágenes, que generan una única etiqueta para toda la imagen (por ejemplo, real.º "deepfake"), la segmentación permite determinar la ubicación exacta de las regiones alteradas dentro de la imagen. Este enfoque resulta especialmente útil en el análisis forense de deepfakes, ya que no solo permite detectar la presencia de manipulación, sino también localizarla espacialmente.



Figura 4: Ejemplo de segmentación semántica. A la izquierda se muestra la imagen original y a la derecha el mapa de segmentación donde cada píxel es clasificado en una categoría semántica distinta.

Como se observa en la Figura 4, la segmentación semántica permite identificar diferentes regiones dentro de una imagen mediante etiquetas asignadas a cada píxel. En el contexto de esta investigación, en lugar de múltiples categorías semánticas, el objetivo consiste en distinguir únicamente entre regiones manipuladas y regiones auténticas dentro del rostro.

6.5.4. Formulación del problema como segmentación binaria

En el contexto de esta investigación, el problema se formula como una tarea de segmentación binaria, donde cada píxel del rostro es clasificado en una de dos categorías: alterado o no alterado. El objetivo del modelo es aprender una función que, a partir de una imagen facial de entrada, genere una máscara binaria que indique las regiones manipuladas. De esta forma, los píxeles pertenecientes a zonas alteradas se representan con el valor 1, mientras que los píxeles correspondientes a regiones auténticas se representan con el valor 0. Esta formulación permite localizar con precisión las áreas afectadas por manipulaciones digitales.

6.6. Arquitectura U-Net

6.6.1. Que es U-Net

La arquitectura que compone a U-Net es una serie de redes neuronales convolucionales diseñada específicamente para tareas de segmentación de imágenes. Fue propuesta en 2015 por Olaf Ronneberger, Philipp Fischer y Thomas Brox Ronneberger et al. [2015] y fue diseñada con el objetivo principal de realizar una segmentación adecuada y precisa en imágenes biomédicas, donde es necesario identificar estructuras específicas al nivel de los píxeles.

A diferencia de los modelos de clasificación tradicionales que generan una etiqueta global para toda la imagen, la arquitectura de U-Net genera una predicción más específica, es decir una

etiqueta para cada píxel. Esto permite localizar con precisión las regiones donde es necesario identificar la ubicación exacta de un objeto o una alteración.

El nombre de la arquitectura proviene de su forma característica U, compuesta por una etapa de contracción o codificación (encoder) seguida por una etapa de expansión o decodificación (decoder). Esta estructura permite capturar tanto información contextual global como detalles espaciales finos.

6.6.2. Componentes principales de la arquitectura

La arquitectura U-Net se compone de tres elementos fundamentales:

Encoder

El encoder es responsable de extraer características de la imagen de entrada. Esta etapa consiste en una serie de capas convolucionales seguidas de operaciones de max pooling, que reducen progresivamente la resolución espacial mientras aumentan la profundidad de los mapas de características.

El objetivo del encoder es capturar información semántica y contextual, permitiendo que la red identifique patrones complejos presentes en la imagen.

En términos generales, cada bloque del encoder incluye:

- Dos convoluciones 3×3
- Una función de activación (comúnmente ReLU)
- Una operación de max pooling 2×2 para reducir la resolución de la imagen

Esta reducción progresiva permite que la red aprenda representaciones cada vez más abstractas de la imagen.

Decoder

El decoder tiene como objetivo reconstruir la resolución espacial de la imagen para generar un mapa de segmentación del mismo tamaño que la imagen original.

En esta etapa se utilizan operaciones de up-sampling o transposed convolution, que incrementan progresivamente la resolución de los mapas de características.

Cada bloque del decoder incluye:

- Up-convolution o up-sampling
- Concatenación con mapas de características del encoder
- Dos convoluciones de 3×3

El decoder permite recuperar los detalles espaciales que se pierden durante el proceso de reducción de resolución en el encoder.

Skip connections

Uno de los elementos más importantes de U-Net son las skip connections.

Estas conexiones enlazan directamente las capas del encoder con las capas correspondientes del decoder, concatenando los mapas de características de ambas etapas.

El propósito de estas conexiones es preservar información espacial de alta resolución, que de otro modo se perdería durante el proceso de reducción de resolución del encoder.

Gracias a estas conexiones, el modelo puede combinar:

- **Información contextual global** (aprendida en capas profundas)

■ Información espacial detallada

Esto permite generar segmentaciones más precisas, especialmente en los bordes de los objetos.




Figura 5: Arquitectura de U-Net propuesta por Ronneberger et al. Ronneberger et al. [2015]. La red está compuesta por una ruta de contracción (encoder) que extrae características mediante convoluciones y max pooling, y una ruta de expansión (decoder) que reconstruye la resolución espacial mediante operaciones de up-sampling. Las skip connections permiten transferir información espacial de alta resolución desde el encoder al decoder, mejorando la precisión de la segmentación.

La Figura 5 muestra la arquitectura original de U-Net propuesta por Ronneberger et al. En la parte izquierda se encuentra la ruta de contracción (encoder), donde la resolución espacial de la imagen se reduce progresivamente mediante operaciones de max pooling mientras aumenta el número de mapas de características. En la parte derecha se encuentra la ruta de expansión (decoder), donde la resolución se recupera mediante operaciones de up-convolution. Las conexiones laterales entre ambas rutas permiten combinar información semántica profunda con detalles espaciales de alta resolución, lo que mejora la precisión en tareas de segmentación.

6.6.3. Diferencia entre clasificación y segmentación

En problemas de clasificación de imágenes, el objetivo del modelo es asignar una única etiqueta a toda la imagen. Para lograrlo, las redes suelen reducir progresivamente la resolución de los mapas de características hasta obtener una representación compacta de alto nivel.

Sin embargo, en tareas de segmentación, el objetivo es generar un mapa denso de predicción, en el cual cada píxel recibe una etiqueta específica.

Esto implica que el modelo debe extraer características globales de la imagen, mantener o reconstruir la información espacial y producir una predicción para cada píxel.

La arquitectura U-Net aborda este problema mediante su estructura encoder-decoder, que permite extraer características profundas mientras reconstruye la resolución espacial necesaria para la segmentación.

En el contexto de la detección de deepfakes, esta diferencia es crucial, ya que el objetivo no es únicamente determinar si una imagen ha sido manipulada, sino localizar las regiones específicas donde ocurre la manipulación.

6.6.4. Variantes de U-Net

Desde su publicación original, se han propuesto múltiples variantes de la arquitectura U-Net con el objetivo de mejorar su desempeño en distintos escenarios.

Entre las variantes más relevantes se encuentran:

- **Attention U-Net:** Utiliza mecanismos de atención que permiten al modelo enfocarse en regiones relevantes de la imagen. Esta variante resulta útil cuando los objetos de interés ocupan una pequeña parte de la imagen.
- **Residual U-Net:** Utiliza conexiones residuales, similares a las utilizadas en redes ResNet, lo que facilita el entrenamiento de redes más profundas y mejora la propagación del gradiente.
- **Multi-scale U-Net:** Usa mecanismos para capturar información a diferentes escalas espaciales, lo que resulta útil en imágenes donde los objetos presentan tamaños variables.

6.6.5. Elección de arquitectura para el escenario de la investigación

En el contexto de esta investigación, el objetivo es detectar y localizar manipulaciones faciales en imágenes mediante segmentación binaria. Este tipo de problema requiere identificar patrones sutiles en la textura, los bordes y las regiones faciales.

La arquitectura U-Net resulta adecuada para este escenario debido a su capacidad para capturar características semánticas complejas, preservar información espacial y generar mapas de segmentación de alta resolución

6.7. Artefactos típicos en deepfakes faciales.

6.7.1. Inconsistencias de textura, bordes e iluminación como huellas forenses

En la detección y localización de manipulaciones faciales, el concepto de "artefacto" se entiende como una huella observable (En el dominio espacial y/o en el dominio de frecuencia) que emerge de los procesos de síntesis, reenactment y mezclado del rostro con su contexto. En esta tesis, dichas huellas se interpretan como señales que un segmentador (p. ej., U-Net) puede capturar razonablemente a partir de supervisión con máscara binaria, siempre bajo la premisa de que la inferencia se realiza sin imagen de referencia y con evidencia visual (overlay) como salida explicativa.

De forma operativa, el conjunto de artefactos más consistente reportado en la bibliografía se concentra en inconsistencias locales del rostro, donde el contenido alterado tiende a romper coherencias finas que un rostro real mantiene de manera natural. En particular, y en concordancia con los alcances del proyecto, destacan tres familias de inconsistencias:

- Texturas.
- Bordes/contornos.
- Iluminación/sombras.

Estas categorías no son excluyentes; con frecuencia coexisten y se manifiestan en ubicaciones variables dentro de la región facial, lo cual justifica tratar el problema como localización/segmentación y no únicamente como clasificación global. Amerini et al. [2025], Murguía Serrano et al. [2025b]

Las inconsistencias de textura se asocian a micro-patrones del rostro (poros, grano, detalles de piel, transiciones finas) que pueden ser suavizados, reconstruidos de forma imperfecta o re-texturizados”por el generador y por el posprocesamiento. En términos forenses, la alteración puede introducir una apariencia demasiado lisa, repetitiva o con ruido residual no coherente con el resto de la imagen. Dado que estas huellas son sutiles y suelen estar por debajo del umbral de percepción humana, la bibliografía reciente enfatiza la explotación de trazas de textura finas como un recurso discriminativo de alta utilidad, particularmente cuando las señales semánticas (identidad, género, rasgos globales) inducen sobreajuste. Jiang et al. [2025], Jin et al. [2025]

Las inconsistencias en bordes/contornos aparecen principalmente por el acoplamiento imperfecto entre la región sintética y el rostro o su vecindad (líneas de mezcla, transiciones abruptas o halos), así como por errores de alineación y deformación al adaptar una cara generada al encuadre original. En imágenes fijas, este tipo de huellas puede observarse como micro-discontinuidades en límites faciales, contornos de boca/ojos, o regiones con transiciones de color y detalle que no siguen la continuidad esperada. En un esquema de segmentación facial, dichas discontinuidades resultan relevantes porque tienden a concentrarse en fronteras de la manipulación, lo que favorece la obtención de máscaras aproximadas aun cuando no se persiga precisión extrema a nivel píxel. Amerini et al. [2025], Jiang et al. [2025]

En el caso de iluminación y sombras, la evidencia se relaciona con inconsistencias fotométricas: direccionalidad de la luz no compatible, sombras no congruentes, reflejos especulares atípicos o discrepancias entre el sombreado del rostro y el contexto. Aunque los generadores contemporáneos pueden producir coherencia global alta, persisten casos donde el modelado de la reflectancia facial o la integración con la escena introduce errores locales. Para un segmentador, estas señales se expresan como patrones de gradiente y textura que rompen la continuidad fotométrica, particularmente en regiones de alta complejidad visual (ojos, labios, zonas de transición entre piel y rasgos faciales).Amerini et al. [2025], Murguía Serrano et al. [2025b]

6.7.2. Señales de alta frecuencia y residuos de textura en la localización de manipulaciones

Una parte sustantiva de estas huellas se concentra en altas frecuencias y en residuos de textura, los cuales suelen ser imperceptibles en inspección directa pero detectables al analizar componentes finos del contenido. En este marco, diversos enfoques recientes sostienen que, al enfatizar señales de alta frecuencia o al modelar residuos asociados a textura degradada, es posible mejorar la sensibilidad a trazas de manipulación que no se evidencian en representaciones de baja frecuencia. En particular, se reportan estrategias orientadas a ”minar”trazas de alta frecuencia y textura degradada para localizar regiones manipuladas y reforzar la capacidad de generalización en escenarios cambiantes. Jiang et al. [2025], Qiao et al. [2025]

En consecuencia, ha ganado tracción la idea de incorporar mecanismos explícitos de realce de textura y de supresión de semántica facial, con el objetivo de forzar al modelo a atender inconsistencias finas en lugar de correlaciones espurias (p. ej., identidad o regularidades del conjunto de datos). Por ejemplo, se han propuesto módulos de minería y realce de textura a nivel local, combinados con extracción de pistas globales en frecuencia mediante descomposición multi-escala (p. ej., wavelets), de modo que el detector integre evidencia espacial y espectral

en una sola decisión Jin et al. [2025]. Este tipo de diseño es congruente con el supuesto de que los rastros útiles suelen residir en componentes finos (textura y detalles), mientras que la información de baja frecuencia se correlaciona más con apariencia global y puede inducir sobreajuste. Jin et al. [2025], Qiao et al. [2025]

6.7.3. Degradación por compresión y reescalado: implicaciones metodológicas

Sin embargo, la compresión y el reescalado constituyen una fuente de degradación crítica porque atenúan precisamente las señales finas que los detectores buscan explotar. En plataformas de mensajería y redes sociales, la recompresión introduce efectos de bloque, cuantización y pérdida de microdetalle; por tanto, los artefactos del canal pueden enmascarar o distorsionar los artefactos de manipulación. En el caso del alcance del proyecto, esta interacción es especialmente relevante, ya que los artefactos de compresión pueden confundirse con artefactos de deepfake, elevando falsos positivos o falsos negativos en imágenes de baja resolución o con compresión severa. Gao et al. [2024], Li et al. [2025b]

Bajo esta problemática, la bibliografía reciente propone estrategias específicas para robustez ante compresión, incluyendo el modelado explícito de efectos de bloque y el entrenamiento con datos comprimidos para aproximar condiciones reales de despliegue. En particular, se han reportado marcos que buscan reducir la atención a artefactos engañosos inducidos por compresión en redes sociales, así como enfoques de realce de alta frecuencia diseñados para contenido altamente comprimido, lo que refuerza la idea de que la robustez no es un subproducto automático del entrenamiento convencional, sino una condición que debe inducirse mediante diseño y protocolo experimental. Gao et al. [2024], Li et al. [2025b]

Finalmente, la implicación metodológica es directa: las degradaciones más comunes (compresión, re-escalado y blur) deben considerarse explícitamente en entrenamiento y/o evaluación para evitar conclusiones optimistas en escenarios idealizados. En particular, si el modelo aprende huellas de alta frecuencia y residuos de textura, entonces el protocolo debe incluir perturbaciones que simulen la pérdida de micro detalle y el re-empaquetado típico de plataformas, además de analizar el impacto en la localización (máscara/overlay) y no solo en una etiqueta. Este punto se retoma en los apartados 1.8 y 1.10 al discutir la relación entre entrenamiento, evaluación y robustez bajo cambio de dominio. Amerini et al. [2025], Murguía Serrano et al. [2025b]

6.8. Datos, etiquetado y sesgos.

6.8.1. Panorama de conjuntos de datos para detección de deepfakes

La validez de un modelo de detección y localización de manipulaciones faciales está condicionada, en primer término, por las propiedades del conjunto de datos utilizado en su entrenamiento y evaluación. Esta dependencia no es trivial: la distribución de ejemplos (En cuestión de técnicas de falsificación representadas, condiciones de captura, posprocesamiento aplicado y diversidad de identidades) determina el límite que el modelo puede inducir y, en consecuencia, el alcance real de sus predicciones. La bibliografía reciente es consistente al señalar que métricas elevadas en evaluación no garantizan desempeño equivalente en escenarios distintos al de entrenamiento; por tanto, el conjunto de datos debe entenderse como una decisión de suma importancia y prioridad ya que conlleva implicaciones directas sobre la interpretación de los resultados. Amerini et al. [2025], Li et al. [2025a]

En el panorama de banco de pruebas disponibles para detección de deepfakes, los conjuntos de referencia han evolucionado desde colecciones pequeñas y controladas hacia conjuntos de datos de mayor escala y diversidad de condiciones. FaceForensics++ introdujo un marco sistemático de manipulaciones etiquetadas con máscaras de píxel modificado; conjuntos posteriores como Celeb-DF y el DFDC ampliaron la cobertura hacia distribuciones más cercanas

a la circulación real de contenido. Evaluaciones recientes como Deepfake-Eval-2024 reportan que modelos entrenados en bancos de pruebas académicos exhiben degradación pronunciada ante contenido generado en 2024, lo que evidencia que los conjuntos existentes no capturan suficientemente la dinámica de los generadores actuales ni las condiciones de distribución de plataformas Banerjee et al. [2025], Chandra et al. [2025]. Esta brecha motiva la construcción de conjuntos de datos propios calibrados al dominio de aplicación específico, en lugar de apoyarse exclusivamente de los ya consolidados cuya distribución puede diferir de manera significativa según el objetivo.

6.8.2. Sesgos típicos y estrategia de construcción del conjunto de datos propio

En el marco del presente proyecto, se establece como objetivo la construcción de un conjunto de datos propio de 50,000 imágenes, con distribución balanceada entre muestras reales y manipuladas, y particionado en subconjuntos de entrenamiento, validación y prueba con proporciones que garanticen suficiencia variación en cada fase. Cada imagen de la partición manipulada incluye una máscara binaria que delimita la región facial alterada, producida mediante criterio de anotación consistente y revisada para verificar que la región señalada corresponde al área de intervención del generador. Dicha acción responde a la necesidad de controlar explícitamente las características de la distribución de entrenamiento y de ajustar el protocolo de etiquetado a las condiciones operativas del detector propuesto, sin depender de restricciones de licencia ni de criterios de anotación concebidos para objetivos distintos. Hu et al. [2024], Li et al. [2025a]

Los sesgos típicos presentes en conjuntos de datos de deepfakes pueden clasificarse en sesgos de dominio, de escena y de método. El sesgo de dominio ocurre cuando el conjunto de datos proviene predominantemente de una fuente o generador específico, de modo que el modelo captura falsas relaciones asociadas a dicho origen en lugar de señales forenses transferibles. El sesgo de escena abarca variaciones en iluminación, rango de encuadre, oclusiones y tamaño de la región facial que, si no se representan con suficiente diversidad, limitan la robustez ante condiciones no vistas. El sesgo de método, particularmente relevante para este trabajo, se manifiesta cuando el conjunto de datos incluye únicamente manipulaciones generadas por un subconjunto acotado de técnicas conocidas, lo que restringe la generalización a métodos de síntesis no presentes en el entrenamiento. Amerini et al. [2025], Yang et al. [2025] Si bien la construcción propia busca mitigar estas fuentes de sesgo mediante selección diversificada de imágenes y técnicas de falsificación, no se garantiza cobertura exhaustiva de todas las variantes de generación actuales ni de condiciones extremas de captura.

6.8.3. Etiquetado de máscaras binarias y protocolo de partición

El proceso de etiquetado de máscaras binarias constituye una fuente independiente de varianza sobre la metodología. En el contexto de este proyecto, la máscara binaria se define como una región aproximada de la zona facial manipulada, con tolerancia a imprecisiones de borde en un rango razonable, dado que el objetivo del segmentador es la localización funcional y no la delimitación perfecta del píxel en la alteración. Esta decisión es lo más coherente con lo reportado en la bibliografía: la anotación de regiones manipuladas puede presentar inconsistencias entre una anotación y otra, especialmente en zonas de transición suave entre contenido real y falso, y el modelo debe ser evaluado bajo criterios de coincidencia que contemplen dicha tolerancia de marcado de zonas. Hu et al. [2024], Li et al. [2025a]. Asimismo, errores sistemáticos en el etiquetado —por ejemplo, inclusión de regiones no manipuladas dentro de la máscara o exclusión de huellas de unión de regiones— representan un riesgo de sesgo de anotación que puede traducirse en supervisión ruidosa y en una señal de un entrenamiento no eficiente, aspecto que debe considerarse al interpretar los valores de las métricas de segmentación obtenidos del modelo.

6.8.4. Generalización acotada y evaluación con datos fuera del dominio de entrenamiento

Las limitaciones explícitas del conjunto de datos propuesto incluyen, en primer lugar, la restricción a imágenes de resolución y calidad suficiente para que la región facial sea procesable por la arquitectura U-Net; en consecuencia, imágenes con compresión severa o resolución inferior al umbral operativo pueden degradar la calidad de la máscara producida sin que esto refleje un fallo estructural del modelo ante contenido de calidad estándar. En segundo lugar, la generalización del sistema se declara acotada a las técnicas de manipulación representadas en el conjunto de datos de entrenamiento: el desempeño ante métodos de síntesis no vistos durante el entrenamiento no se garantiza y debe evaluarse con cuidado en escenarios de evaluación con datos nuevos o generadores. Banerjee et al. [2025], Yang et al. [2025]. Estas limitaciones no invalidan el alcance del proyecto; sin embargo, deben enunciarse explícitamente para que la interpretación de las métricas en la fase experimental sea coherente con el marco teórico aquí establecido. La necesidad de particiones bien definidas y de protocolos de evaluación comparables se conecta directamente con los principios de replicabilidad y validez interna del experimento. La partición de entrenamiento debe excluir filtraciones de identidades o escenas hacia el conjunto de prueba, dado que dicha contaminación puede inflar artificialmente las métricas sin reflejar capacidad de generalización real. El conjunto de prueba debe representar condiciones distintas a las del entrenamiento para que la evaluación tenga valor diagnóstico y no meramente confirmatorio. Chandra et al. [2025]. La evaluación con nuevos datos, entendida como la medición de desempeño ante datos provenientes de una distribución distinta a la del entrenamiento, representa el estándar más exigente para afirmar generalización en modelos de detección y localización de deepfakes. La bibliografía reciente documenta de forma consistente que la degradación al probar con datos nuevos puede ser pronunciada incluso en modelos con desempeño elevado en conjuntos de datos de su entrenamiento, debido a la captura de firmas de generador o de regularidades de escena específicas del dominio de entrenamiento. Alrashoud [2025], Yang et al. [2025]. En el presente proyecto, la evaluación con datos nuevos no constituye el objetivo principal de la tesis, pero se reconoce como una limitación inherente al protocolo de validación y se declara como una dirección de trabajo futuro, en coherencia con los alcances y límites definidos en la metodología. Esta declaración es relevante para que los resultados reportados sean interpretados en el marco de una generalización acotada y no como indicadores de desempeño universal del sistema.

6.9. Funciones de pérdida y desbalance de clases.

6.9.1. Desbalance de clases en segmentación binaria de manipulaciones faciales

En el contexto de la segmentación semántica binaria aplicada a la detección de manipulaciones faciales, el desbalance de las clases constituye un problema que condiciona directamente el diseño de la función de pérdida. En una imagen facial sometida a manipulación parcial, los píxeles pertenecientes a la región alterada representan una fracción minoritaria respecto al total de píxeles de la región facial; cuando la modificación afecta únicamente zonas acotadas (por ejemplo, el contorno labial, la región periocular o áreas de fusión) la proporción entre píxeles alterados y no alterados puede ser extremadamente reducida. Bajo estas condiciones, una función de pérdida basada en entropía cruzada binaria (BCE) evaluada sin corrección sobre el total de píxeles asigna el mismo peso a cada uno, de modo que un modelo que predijera de forma uniforme la clase no alterada en toda la imagen obtendría una métrica de exactitud elevada sin capturar ninguna señal discriminativa sobre la región de interés. Este fenómeno, denominado convergencia trivial hacia la clase mayoritaria, implica que los gradientes de entrenamiento quedan dominados por la contribución de los píxeles no alterados, suprimiendo la capacidad

del segmentador para aprender las huellas localizadas que distinguen la región manipulada Hu et al. [2024], Li et al. [2025a].

6.9.2. Taxonomía de funciones de pérdida: distribución por píxel y solapamiento de región

Como respuesta al desbalance descrito, la bibliografía de segmentación establece una taxonomía de funciones de pérdida, organizadas en torno al tipo de señal que optimizan: pérdidas basadas en distribución por píxel y pérdidas basadas en solapamiento de región. En el primer grupo, la Focal loss constituye una modificación directa de la BCE que introduce un factor de modulación dependiente de la probabilidad predicha, de modo que los píxeles fácilmente clasificables (aquellos de la clase mayoritaria, correctamente predichos con alta confianza) reciben un valor reducido, mientras que los píxeles difíciles o minoritarios concentran el gradiente útil. En el segundo grupo, la Dice loss optimiza el coeficiente de solapamiento entre la máscara predicha y la máscara de referencia real, siendo invariante a la proporción absoluta entre clases; al evaluar directamente el coeficiente F1 sobre los conjuntos de píxeles predichos y reales, penaliza de forma proporcional las regiones pequeñas omitidas independientemente de su tamaño relativo. La Tversky loss extiende este enfoque mediante parámetros asimétricos que controlan la penalización relativa sobre falsos positivos y falsos negativos, permitiendo priorizar la recuperación (recall) de la clase minoritaria; su variante Focal Tversky incrementa adicionalmente la sensibilidad a regiones pequeñas difíciles mediante un parámetro exponencial análogo al de la Focal loss. La bibliografía especializada ha documentado de forma consistente que las pérdidas compuestas (combinaciones del tipo BCE+Dice o Focal+Dice) superan a las pérdidas simples en tareas de segmentación binaria con distribuciones desbalanceadas, al integrar la estabilidad del gradiente distribuido por píxel con la sensibilidad al solapamiento de región. Azad et al. [2023]

El problema del desbalance de clases no se limita al nivel de píxel: también se manifiesta en formulaciones de clasificación multi-etiqueta donde ciertas categorías de manipulación facial se encuentran subrepresentadas en el conjunto de dato de entrenamiento. Los autores Deng et al. [2025] abordan esta condición en un sistema de detección multi-etiqueta incorporando la función de pérdida asimétrica polinomial (APL, por su sigla en inglés), la cual penaliza con mayor peso los falsos negativos que los falsos positivos; la lógica asimétrica de la APL es funcionalmente análoga a la de la Tversky loss en el dominio de segmentación, en tanto que ambas buscan desplazar el equilibrio del entrenamiento hacia la recuperación de instancias minoritarias o difíciles. Aunque el contexto de aplicación difiere (clasificación multi-etiqueta por región facial versus segmentación binaria a nivel de píxel), el principio de ponderación asimétrica se transfiere directamente al problema de localización de deepfakes: la región alterada constituye una clase con escasa representación positiva, y una pérdida no simétrica o basada en región es necesaria para evitar que el modelo la ignore durante el entrenamiento. Deng et al. [2025]. Este nexo entre enfoques de detección de distintas granularidades refuerza la coherencia teórica de seleccionar funciones de pérdida con propiedades asimétricas o compuestas en la formulación de segmentación propuesta en este proyecto.

6.9.3. Criterio de selección: pérdidas compuestas y ponderación asimétrica

Para la tarea de segmentación semántica binaria formulada en este trabajo, la selección de la función de pérdida debe satisfacer dos requisitos complementarios: estabilidad durante el entrenamiento sobre lotes de gran tamaño y sensibilidad a regiones alteradas de área reducida. Con base en la evidencia reportada en la bibliografía de segmentación, las pérdidas compuestas que combinan un componente distribuido por píxel (BCE o Focal) con un componente basado

en solapamiento de región (Dice) superan de forma consistente a las pérdidas simples en tareas de segmentación binaria desbalanceada, incluidas arquitecturas basadas en U-Net. Azad et al. [2023]. En el contexto específico de detección y localización de deepfakes con supervisión por máscara binaria, la incorporación de supervisión a nivel de píxel ha demostrado mejorar la especificidad espacial del modelo y su capacidad de producir evidencia visual verificable sobre las regiones de interés forense. Hu et al. [2024], Li et al. [2025a]. En consecuencia, el criterio teórico que guía la elección de la función de pérdida en esta tesis se fundamenta en la combinación de estabilidad de convergencia (aportada por el componente BCE o Focal) y sensibilidad a solapamiento en regiones pequeñas (aportada por el componente Dice), dado que esta composición minimiza el riesgo de convergencia trivial sin sacrificar la capacidad de localización sobre manipulaciones de área acotada. Azad et al. [2023], Deng et al. [2025].

La declaración explícita de estas consideraciones desde el marco teórico habilita una interpretación coherente de los resultados experimentales: si la región manipulada ocupa una fracción extremadamente pequeña de la imagen, incluso una función de pérdida compuesta bien calibrada puede generar máscaras que presenten bajas calificaciones en la métrica de Intersección sobre Unión (conocida como IoU, por sus siglas en inglés), lo cual reflejaría la dificultad intrínseca del caso y no un fallo estructural del modelo. Adicionalmente, la degradación inducida por compresión (descrita en la sección 1.7) afecta la señal discriminativa disponible para la función de pérdida: las imágenes comprimidas pierden información de alta frecuencia que el modelo emplea para distinguir entre píxeles alterados y no alterados, reduciendo la relación señal-ruido efectiva durante el entrenamiento y potencialmente desplazando la distribución de gradientes de forma desfavorable para la clase minoritaria. Estas condiciones deben considerarse en el protocolo experimental al seleccionar y justificar la función de pérdida, al analizar la estabilidad del entrenamiento y al evaluar el desempeño bajo distintos niveles de compresión, en coherencia con los alcances y límites declarados del sistema. Azad et al. [2023], Li et al. [2025a].

6.10. Métricas de evaluación para segmentación y salida forense.

6.10.1. Métricas de solapamiento de región: IoU y coeficiente Dice

La selección y definición precisa de las métricas de evaluación constituye un requisito previo para determinar en qué medida el modelo satisface los objetivos declarados del proyecto, en particular la producción de una máscara binaria que delimite la región facial manipulada con un criterio de éxito centrado en la localización funcional y no en la replicación exacta de cada píxel alterado. Esta distinción no es una decisión ligera: la exactitud por píxel (*pixel accuracy*), definida como la fracción de píxeles correctamente clasificados sobre el total de la imagen, resulta una métrica inadecuada para el caso de segmentación binaria con desbalance de clases, dado que un modelo que prediga la clase no alterada de forma uniforme puede alcanzar valores elevados de exactitud sin detectar ninguna región manipulada. La bibliografía especializada en evaluación de segmentación documenta de manera consistente que este comportamiento, denominado sesgo de clase mayoritaria, invalida la interpretación directa de la exactitud como indicador de desempeño cuando la región de interés representa una fracción minoritaria de los píxeles totales. Azad et al. [2023], Seghier [2024]. En consecuencia, el protocolo de evaluación de este proyecto adopta métricas de solapamiento de región como principal criterio cuantitativo.

Las métricas primarias para la evaluación del segmentador propuesto son la Intersección sobre la Unión (IoU, también denominada índice de Jaccard) y el coeficiente Dice (equivalente a la puntuación F1 a nivel de píxel). El IoU se define formalmente como la razón entre el número de píxeles clasificados correctamente como alterados en ambas máscaras (verdaderos positivos, VP) y el total de píxeles presentes en la unión de la máscara predicha y la máscara de referencia real, es decir:

$$\text{IoU} = \frac{\text{VP}}{\text{VP} + \text{FP} + \text{FN}}$$

donde FP denota falsos positivos y FN falsos negativos. El Dice, por su parte, se define como:

$$\text{Dice} = \frac{2 \cdot \text{VP}}{2 \cdot \text{VP} + \text{FP} + \text{FN}}$$

lo que equivale a la media armónica de la precisión y la exhaustividad a nivel de píxel. Ambas métricas comparten la propiedad de ignorar los verdaderos negativos (Píxeles no alterados correctamente predichos) y evaluar exclusivamente el solapamiento sobre la clase positiva, lo que las hace intrínsecamente robustas al desbalance entre clases que caracteriza el problema de localización de deepfakes faciales. Existe una relación matemática directa entre ambas, expresable como:

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}}$$

de modo que reportar una implica información equivalente sobre la otra; sin embargo, la bibliografía de detección de manipulaciones utiliza con frecuencia ambas de forma complementaria para facilitar la comparación con trabajos previos. Azad et al. [2023], Seghier [2024].

6.10.2. Precisión, exhaustividad y definición operativa de éxito del sistema

Como métricas complementarias, la precisión por píxel:

$$\text{Precisión} = \frac{\text{VP}}{\text{VP} + \text{FP}}$$

y la exhaustividad por píxel (*Recall*):

$$\text{Recall} = \frac{\text{VP}}{\text{VP} + \text{FN}}$$

proveen una descomposición del error útil para caracterizar el tipo de fallo dominante del segmentador: valores de exhaustividad bajos con precisión alta indican que el modelo localiza correctamente las regiones manipuladas cuando las detecta, pero omite una fracción significativa de ellas; el patrón inverso señala sobre detección, es decir, la tendencia a marcar como alteradas regiones no manipuladas. En el contexto forense del presente proyecto, la exhaustividad reviste mayor relevancia operativa que la precisión, dado que la omisión de una región manipulada (falso negativo) representa un error más grave que la señalización de una zona no alterada dentro del rostro (falso positivo). Esta asimetría ya fue fundamentada en la sección 1.9 al discutir el diseño de la función de pérdida, y se traslada directamente al protocolo de evaluación: las métricas deben reportarse de forma desagregada para permitir diagnósticos sobre el comportamiento del modelo ante manipulaciones de área reducida. Hu et al. [2024], Li et al. [2025a].

6.10.3. Evaluación visual mediante overlays en el contexto forense

La definición operativa de "éxito" del sistema en este proyecto no exige coincidencia perfecta a nivel de píxel entre la máscara predicha y la máscara de referencia real, sino la localización funcional de la región aproximadamente manipulada dentro del área facial. Esta decisión se fundamenta en tres consideraciones interdependientes. Primera, las propias anotaciones de referencia presentan incertidumbre inherente en bordes de transición suave entre contenido real y manipulado, de modo que exigir coincidencia píxel a píxel introduciría una penalización artificial por imprecisión del etiquetado y no por fallo del modelo. Segunda, el uso forense del

sistema requiere una evidencia visual que permita al analista humano orientar su inspección hacia la región sospechosa, objetivo que se satisface con una máscara aproximada sin necesidad de precisión extrema en los contornos. Tercera, la bibliografía reciente sobre la localización de deepfakes documenta que los métodos con supervisión por máscara binaria producen indicadores IoU que, en condiciones estándar de evaluación intra-dominio, se sitúan en rangos funcionales de localización sin alcanzar los valores de modelos que disponen de anotaciones densas y de alta fidelidad; en consecuencia, el criterio de éxito adoptado corresponde a una región aproximada coherente con la zona de intervención del generador, con tolerancia a imprecisiones de borde razonables y sin requerir delineación perfecta del área alterada. Li et al. [2025a], Xu et al. [2024]. Bajo este criterio, un umbral de IoU que refleje localización funcional —región centrada y orientada correctamente sobre la zona manipulada— constituye el indicador primario de desempeño, mientras que valores inferiores en imágenes con regiones muy pequeñas o con compresión severa se interpretan como consecuencia de la dificultad esencial del caso evaluado y no como fallo estructural del modelo. La evaluación visual mediante overlays (representaciones gráficas que superponen la máscara predicha sobre la imagen original con codificación cromática de la región manipulada) constituye un componente de evaluación complementario e indispensable en el contexto forense del proyecto. A diferencia de las métricas cuantitativas, que colapsan el desempeño espacial del segmentador en un escalar, los overlays permiten identificar patrones de error que no son capturables por un indicador agregado: por ejemplo, si el modelo localiza correctamente el tipo de región manipulada (contorno labial, región periocular) pero desplaza sistemáticamente la máscara hacia zonas adyacentes, el IoU reportado podría ser bajo a pesar de que la salida sea forense y operativamente útil. La bibliografía sobre interpretabilidad en detección de deepfakes subraya de manera consistente que los sistemas orientados a aplicaciones de alto riesgo (pericia forense, análisis periodístico, procedimientos legales) requieren salidas explicativas que combinen la decisión cuantitativa con evidencia visual verificable por un analista humano, dado que una etiqueta binaria sin soporte espacial no satisface los estándares de trazabilidad exigidos en dichos contextos. Amerini et al. [2025], Miao et al. [2025], Xu et al. [2024]. En el presente proyecto, los overlays se reportan como parte de la evaluación del cuarto objetivo específico, con el propósito explícito de facilitar la interpretación humana de los resultados y de documentar visualmente los casos representativos de cada nivel de desempeño cuantitativo. La interpretación de los indicadores de segmentación debe contemplar, adicionalmente, el efecto de las degradaciones descritas en las secciones 1.7 y 1.8 sobre el desempeño medible del modelo. La compresión y el re-escalado (condiciones prevalentes en imágenes provenientes de redes sociales y plataformas de mensajería) suprimen las huellas de alta frecuencia y reducen la micro detalle de textura que el segmentador utiliza como señal discriminativa, afectando tanto la calidad de la máscara predicha como la correspondencia con la máscara de referencia real. En este escenario, la degradación inducida por el canal puede producir caídas en el IoU y el Dice que no reflejan una pérdida de capacidad de localización del modelo, sino la reducción de la señal forense disponible para la decisión. Esta consideración es coherente con la evidencia reportada en trabajos recientes de evaluación en condiciones reales, que documentan degradación pronunciada de los indicadores estándar cuando los detectores se aplican a contenido comprimido o distribuido en plataformas. Gao et al. [2024], Li et al. [2025b].

En consecuencia, el protocolo de evaluación del presente proyecto debe distinguir entre el desempeño sobre imágenes de calidad estándar y el desempeño sobre imágenes con degradaciones aplicadas, de modo que las métricas reportadas reflejen con precisión el alcance real del sistema y no un desempeño idealizado, en coherencia con los límites declarados en los alcances del proyecto respecto a compresión severa y baja resolución.

6.11. Consideraciones forenses y operativas.

6.11.1. Restricciones operativas: inferencia sin imagen de referencia y modo offline

El presente proyecto delimita su alcance al análisis forense de imagen fija en el dominio facial, bajo una restricción operativa fundamental: la inferencia se realiza con una única imagen, sin disponer de una imagen de referencia correspondiente al sujeto en su estado no manipulado. Esta condición, coherente con el escenario forense real en el que la evidencia disponible suele consistir exclusivamente en el material incautado o reportado, obliga a que el segmentador U-Net base su decisión en inconsistencias internas del contenido —patrones residuales de textura, discontinuidades en bordes y gradientes, incoherencias fotométricas— y no en una comparación directa entre pares de imágenes. La ausencia de imagen de referencia reduce el espacio de señales discriminativas disponibles y constituye, por tanto, una limitación estructural del sistema que debe enunciarse de forma explícita: la capacidad del modelo para localizar regiones manipuladas está acotada a la información contenida en la imagen de consulta y a los patrones aprendidos durante el entrenamiento a partir del conjunto de datos etiquetado. Amerini et al. [2025].

En cuanto al modo de operación, el sistema está concebido para análisis forense offline ejecutado en un entorno con GPU dedicada, y no para detección en tiempo real ni para despliegue en dispositivos de borde (móviles, sistemas embebidos o plataformas IoT). Esta decisión es coherente con la naturaleza de la arquitectura U-Net, cuya cadena codificadora-decodificadora con múltiples bloques convolucionales y conexiones de salto demanda una huella de memoria y una carga de cómputo que resultan incompatibles con los recursos limitados de dispositivos de borde o con restricciones de latencia de cuadros por segundo. La bibliografía reciente documenta que los modelos de estado del arte para detección y localización de deepfakes (incluyendo variantes basadas en transformadores y arquitecturas híbridas) dependen de GPU de alto rendimiento y de tiempos de inferencia que no permiten procesamiento en tiempo real en hardware restringido. Bharati et al. [2026]. El escenario forense offline, en contraste, tolera latencias de análisis que van desde segundos hasta minutos por imagen, lo que hace que el requisito computacional de la arquitectura propuesta sea admisible dentro de los alcances del proyecto. Adicionalmente, el análisis offline favorece la trazabilidad del proceso y la reproducibilidad del resultado, aspectos críticos para que la salida del sistema (máscara binaria y overlay) pueda ser documentada y presentada como evidencia visual en un contexto pericial. Miao et al. [2025], Xu et al. [2024].

6.11.2. Salida del sistema: máscara binaria y overlay como evidencia visual

El overlay, entendido como la superposición cromática de la máscara predicha sobre la imagen de consulta, constituye el artefacto de salida orientado al analista humano y no un producto intermedio del sistema. Su función operativa es orientar la inspección hacia la región aproximada de intervención del generador dentro del área facial, sin pretender sustituir ni automatizar el juicio del perito. Esta distinción es relevante: el sistema entrega una hipótesis espacial fundamentada en características aprendidas, pero la validación final y la interpretación en el contexto del caso corresponden al analista humano. La bibliografía sobre detección explicable de deepfakes con orientación forense coincide en que los sistemas orientados a aplicaciones de alto riesgo (pericia judicial, verificación periodística, procedimientos legales) requieren salidas espacialmente verificables que permitan al analista evaluar la coherencia entre la región señalada y las inconsistencias visuales observables, dado que una etiqueta binaria sin soporte espacial no satisface los estándares de trazabilidad exigidos en dichos contextos. Bharati et al. [2026], Xu et al. [2024]. En este marco, la combinación de máscara binaria y overlay no representa una redundancia, sino un par complementario: la máscara habilita la cuantificación (IoU, Dice) y la overlay habilita la interpretación visual estructurada.

6.11.3. Alcances explícitos, limitaciones declaradas y casos difíciles

El sistema no promete, dentro de sus alcances declarados, la identificación del tipo de manipulación aplicada: la salida es exclusivamente una máscara binaria con la distinción alterado/no alterado, sin clasificación de la técnica de falsificación (reemplazo, recreación, generación completa u otras). Asimismo, la segmentación se restringe al área facial y no abarca cabello, cuello, cuerpo, fondo ni elementos externos al rostro; la detección de manipulaciones fuera del área facial queda explícitamente fuera del alcance del proyecto. Esta delimitación responde al diseño del espacio de búsqueda (píxeles faciales) y no a una limitación arquitectónica general: en principio, el mismo paradigma de segmentación podría extenderse a otras regiones, pero dicha extensión requeriría conjuntos de datos y protocolos de etiquetado específicos que no forman parte de la propuesta actual. Finalmente, los casos denominados difíciles (oclusión fuerte como manos, cubrebocas, lentes de gran cobertura, iluminación extrema tales como subexposición o saturación severa y compresión de alta tasa o resolución inferior al umbral operativo del detector) representan condiciones donde el desempeño del segmentador puede degradarse de forma pronunciada, con el consiguiente incremento de falsos positivos o falsos negativos, sin que ello refleje un fallo estructural del modelo ante contenido de calidad estándar. La bibliografía coincide en que la compresión y las oclusiones constituyen fuentes de degradación de señal forense que reducen la relación señal-ruido disponible para la función de pérdida y para la inferencia, lo que puede traducirse en máscaras fragmentadas, desplazadas o de bajo IoU que deben interpretarse a la luz de la dificultad intrínseca del caso y no como indicadores del límite superior de la arquitectura. Almotiri et al. [2024], Gao et al. [2024], Li et al. [2025b].

6.11.4. Conexión del marco teórico con las decisiones metodológicas

La conexión entre el marco teórico y las decisiones metodológicas concretas puede sintetizarse del siguiente modo: la restricción de inferencia sin imagen de referencia (sección 1.1) determina que el modelo opere sobre huellas internas; la elección de segmentación semántica sobre clasificación global (sección 1.3) se fundamenta en la necesidad de producir evidencia espacial verificable; la arquitectura U-Net (sección 1.6) se justifica por su capacidad de recuperar detalle espacial a través de conexiones de salto; las funciones de pérdida compuestas (sección 1.9) responden al desbalance de clases en la región facial manipulada; las métricas IoU y Dice (sección 1.10) constituyen el criterio cuantitativo primario para localización funcional; y el overlay (sección 1.10) satisface el requisito de evidencia visual para el analista forense. Las limitaciones declaradas en la presente sección (inferencia sin referencia, operación offline, restricción al rostro, ausencia de clasificación de tipo, casos difíciles no garantizados) deben considerarse en el protocolo experimental al diseñar las particiones del conjunto de datos, al seleccionar las métricas de reporte y al interpretar los resultados en función del alcance operativo del sistema y no de un desempeño universal. Amerini et al. [2025], Li et al. [2025a], Miao et al. [2025].

Referencias

- S. H. Almotiri, F. Ahmad, M. A. Al Ghamdi, and M. Basher. Deepfake forensics: A survey of digital forensic methods for multimodal deepfake identification on social media. *PeerJ Computer Science*, 10:e2037, 2024. doi: 10.7717/peerj-cs.2037.
- M. Alrashoud. Deepfake video detection methods, approaches, and challenges. *Alexandria Engineering Journal*, 125:265–277, 2025. doi: 10.1016/j.aej.2025.04.007.
- I. Amerini, M. Barni, S. Battiato, P. Bestagini, G. Boato, et al. Deepfake media forensics: Status and future challenges. *Journal of Imaging*, 11(3):73, 2025. doi: 10.3390/jimaging11030073.
- R. Azad, M. Heidary, K. Yilmaz, M. Hüttemann, S. Karimijafarbigloo, Y. Wu, A. Schmeink, and D. Merhof. Loss functions in the era of semantic segmentation: A survey and outlook, 2023.
- S. Banerjee, S. K. Yadav, A. Dhara, and M. Ajij. A survey: Deepfake and current technologies for solutions. In *CEUR Workshop Proceedings (DoSIER 2024)*, 2025.
- Jawadul H. Bappy, Amit K. Roy-Chowdhury, Jason Bhowmik, S. Natarajan, and Bart Pereira. Exploiting spatial structure for localizing manipulated image regions. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 4970–4979, October 2017.
- N. Bharati, A. Hamie, A. Saberi, and B. Garcia-Garcia. Explainable deepfake detection: A multi-model framework with human-interpretable rationales for legal investigation purposes. *Machine Learning with Applications*, 23:100819, 2026. doi: 10.1016/j.mlwa.2025.100819.
- N. A. Chandra, R. Murtfeldt, L. Qiu, A. Karmakar, H. Lee, E. Tanumihardja, K. Farhat, B. Caffee, S. Paik, C. Lee, J. Choi, A. Kim, and O. Etzioni. Deepfake-eval-2024: A multi-modal in-the-wild benchmark of deepfakes circulated in 2024, 2025. v2.
- Liwei Deng, Boda Wu, and Jiandong Wang. A multi-label classification method combined with texture enhancement for deepfake face detection. *Multimedia Systems*, 31:410, 2025. doi: 10.1007/s00530-025-01996-y.
- J. Gao, Z. Xia, G. L. Marcialis, C. Dang, J. Dai, and X. Feng. Deepfake detection based on high-frequency enhancement network for highly compressed content. *Expert Systems with Applications*, 249:123732, 2024. doi: 10.1016/j.eswa.2024.123732.
- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- J. Hu, X. Liao, D. Gao, S. Tsutsui, Q. Wang, Z. Qin, and M. Z. Shou. Detection and localization for deepfake videos with randomly-located tampered traces (delocate), 2024. v5.
- Paul Jaccard. The distribution of the flora in the alpine zone. *New Phytologist*, 11(2):37–50, 1912.
- Q. Jiang, S. Liu, S. Miao, H. Yi, X. Jin, Y. Kou, et al. Robust manipulated media localization and detection based on high frequency and texture features. *Discover Computing*, 28, 2025. doi: 10.1007/s10791-025-09500-w. Article 10.
- X. Jin, Y. Kou, Y. Xie, Y. Zhao, M. L. Mat Kiah, Q. Jiang, and W. Zhou. Learning local texture and global frequency clues for face forgery detection. *Biomimetics*, 10(8):480, 2025. doi: 10.3390/biomimetics10080480.

- Linda Laurier, Ave Giulietta, Arlo Octavia, and Meade Cleti. The cat and mouse game: The ongoing arms race between diffusion models and detection methods, 2024. URL <https://arxiv.org/abs/2410.18866>.
- J. Li, Y. Hu, B. Liu, H. She, and C.-T. Li. Deepfake detection with domain generalization and mask-guided supervision. *Pattern Recognition*, 165:111622, 2025a. doi: 10.1016/j.patcog.2025.111622.
- M. Li, Y. Liu, C. Tan, H. Qin, B. Li, Y. Wei, and Y. Zhao. Pay less attention to deceptive artifacts: Robust detection of compressed deepfakes on online social networks, 2025b. v1.
- Shahlaa Mashhadani, Wisal Hashim Abdulsalam, Wisam Abed Shukur, and Mohammed S. H. Al-Tamimi. Digital forensics method for fake images detection using gan algorithm based on watermarking technique and image content. *Iraqi Journal of Science*, 67(1):40, 2025. doi: 10.24996/ij.s.2025.67.1.40.
- C. Miao, Y. Zhang, W. Gao, M. Luo, W. Feng, Z. Tan, J. Li, A. Liu, Y. Diao, Q. Chu, T. Gong, Z. Li, W. Yao, and J. T. Zhou. Ddl: A dataset for interpretable deepfake detection and localization in real-world scenarios, 2025.
- Y. Mirsky and W. Lee. The creation and detection of deepfakes: A survey. *ACM Computing Surveys*, 54(1):1–41, 2021. doi: 10.1145/3425780. Artículo 7.
- A. Murguía Serrano, J. O. Mena Guerrero, A. Rentería López, and H. Salcido Ramos. Deepfakes: Revisión sistemática de tecnologías, impacto y abordajes para su detección. *Revista de Investigación en Tecnologías de la Información (RITI)*, 13(28):41–51, 2025a.
- J. Y. Murguía Serrano, C. E. De la Toba Noriega, S. Campos Zatarain, L. Y. Aramburo Contreras, and G. Á. Diaz Lucas. Deepfakes: Revisión sistemática de tecnologías, impacto y estrategias de detección. *RITI Journal*, 13(29), 2025b. doi: 10.36825/RITI.13.29.003.
- M. Qiao, R. Tian, and Y. Wang. Towards generalizable deepfake detection with spatial-frequency collaborative learning and hierarchical cross-modal fusion, 2025. v1.
- Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, volume 9351, pages 234–241. Springer, 2015. doi: 10.1007/978-3-319-24574-4_28.
- Andreas Rössler, Davide Cozzolino, Luisa Verdoliva, Christian Riess, Justus Thies, and Matthias Nießner. Faceforensics++: Learning to detect manipulated facial images. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1–11, October 2019.
- M. L. Seghier. Image segmentation evaluation with the dice index: Methodological issues. *International Journal of Imaging Systems and Technology*, 34(6):e23203, 2024. doi: 10.1002/ima.23203.
- C. Tan, Y. Zhao, S. Wei, G. Gu, P. Liu, and Y. Wei. Frequency-aware deepfake detection: Improving generalizability through frequency space learning, 2024. v1.
- Manish R. Tiwari and Sandip S. Patil. Deepfake image detection: A review of existing methods and a hybrid cnn-based proposed framework. In *ICATCICT 2025*, volume 341 of *EPJ Web of Conferences*, page 01043. EDP Sciences, 2025. doi: 10.1051/epjconf/202534101043.

- J. Xu, J. Liu, J. Li, C. Wang, F. Wu, and J. Luo. Fakeshield: Explainable image forgery detection and localization via multi-modal large language models, 2024.
- José Manuel Yagual Castillo. Desarrollo de una aplicación web con machine learning para la detección de deepfakes en casos de suplantación de identidad digital, 2024.
- S. Yang, H. Guo, S. Hu, B. Zhu, Y. Fu, S. Lyu, X. Wu, and X. Wang. Crossdf: improving cross-domain deepfake detection with deep information decomposition. *Frontiers in Big Data*, 8, 2025. doi: 10.3389/fdata.2025.1669488.