



Instituto Politécnico Nacional
Escuela Superior de Ingeniería Mecánica y Eléctrica
Unidad Culhuacán

Estado del arte

Castillo Delgado Angel Ivan
Rojas Lozada Cuauhtli Emiliano

Índice

1. Estado del arte	2
1.1. A multi-label classification method combined with texture enhancement for deep-fake face detection	2
1.2. Desarrollo de una aplicación Web con machine learning para la detección de Deepfakes en casos de suplantación de identidad digital	2
1.3. Deepfake Image Detection: A Review of Existing Methods and a Hybrid CNN-Based Proposed Framework	2
1.4. Digital Forensics Method for Fake Images Detection Using GAN Algorithm . . .	3
1.5. The Cat and Mouse Game: The Ongoing Arms Race Between Diffusion Models and Detection Methods	3

1. Estado del arte

1.1. A multi-label classification method combined with texture enhancement for deepfake face detection

Los autores [1] proponen el modelo Q2L-DeepFake, el cual busca extender la detección tradicional binaria hacia una clasificación multi-etiqueta para identificar manipulaciones en zonas específicas del rostro. La arquitectura utiliza una CNN (ResNet101) con un módulo enfocado a mejorar las texturas para identificar detalles sutiles en capas superficiales, la cual se conecta a un Transformer Decoder encargado de realizar la detección de falsificaciones mediante las etiquetas mencionadas. Finalmente, integran la función de pérdida APL (Asymmetric Polynomial Loss) para manejar el desequilibrio entre clases y el balance de los datos. Para la fase de entrenamiento Los autores mencionan la limitante que tuvieron debido a que los datos están pensados más en la clasificación binaria por lo que utilizaron el data set Seq-Deepfake aplicando un pre-procesamiento para redefinir las etiquetas características del rostro dividiéndolas en 5 categorías: cejas, nariz, labios, ojos y cabello. Con esto, lograron habilitar el aprendizaje multi-etiqueta, ampliando el nivel de distinción del modelo. De igual forma el estudio fundamenta la inclusión de un modelo de mejora de texturas es necesaria debido a que los rastros de falsificación son en su mayoría imperceptibles y se encuentran comúnmente en las frecuencias altas y la información de textura de la imagen, su modelo actúa en las capas superficiales para extraer y amplificar residuos de textura antes que la red abstraiga la información.

1.2. Desarrollo de una aplicación Web con machine learning para la detección de Deepfakes en casos de suplantación de identidad digital

El autor [2] utiliza técnicas de Machine Learning para mitigar los riesgos de la suplantación de identidad digital causada por los Deepfakes. Su propuesta se desarrolla una aplicación web diseñada para asegurar la seguridad digital, permitiendo que usuarios sin un conocimiento previo o especializado puedan analizar imágenes (en formatos como JPG, PNG o TIFF) para confirmar su veracidad.

El autor entrena un modelo mediante TensorFlow y Keras, empleando una Red Neuronal Convolutiva (CNN). Esta arquitectura es utilizada para procesar la retícula de la imagen y extraer características faciales complejas, permitiendo al sistema identificar inconsistencias imperceptibles para el ojo humano. El modelo final aplica una clasificación binaria tradicional, priorizando la accesibilidad y la prevención del fraude sobre la complejidad arquitectónica.”

1.3. Deepfake Image Detection: A Review of Existing Methods and a Hybrid CNN-Based Proposed Framework

En esta investigación, los autores [3] realizan una revisión crítica de las limitantes actuales en la detección de Deepfakes, destacando problemas como el sesgo en los conjuntos de datos y la falta de generalización en escenarios reales. Para mitigar estas deficiencias, proponen una arquitectura híbrida basada en CNN que integra ResNet-50 (enfocada en bloques residuales) para una extracción robusta de características profundas, conectada a una red VGG-16 que actúa como clasificador especializado.

Emplean pesos pre-entrenados de ImageNet para ambas redes y diseñan una estrategia de entrenamiento en dos fases: primero, congelan las capas inferiores de VGG-16 (que detectan patrones visuales simples como bordes) para ajustar solo las capas superiores utilizando las características extraídas por ResNet; posteriormente, realizan un ajuste fino (fine-tuning) selectivo

en las capas superiores de ResNet-50 junto con el clasificador para especializar el sistema en la detección de artefactos de manipulación. Este enfoque, validado sobre los datasets Celeb-DF y DFDC, busca equilibrar la capacidad de extracción de características locales profundas con una clasificación más eficiente, priorizando la robustez frente a post-procesamientos comunes como la compresión y la redimencion.

1.4. Digital Forensics Method for Fake Images Detection Using GAN Algorithm

Los autores [4] presentan un método de detección usando técnicas forenses basado en marcas de agua y contenido de imágenes falsas generadas con GAN, específicamente usando StyleGAN2-ADA. Se propone un flujo donde se toman imágenes, se re dimensiona a 256 x 256 píxeles y se les inserta texto invisible de 5,000 caracteres mediante dos técnicas, bit menos significativo y transformada discreta del coseno, luego esas imágenes con marca de agua se utilizan como insumo para generar imágenes sintéticas con StyleGAN2-ADA en un entorno tipo Google Colab con GPU.

Se evalúan el impacto de las marcas de agua, la efectividad para detectar falsificación al extraer el texto oculto, reportando que el texto extraído desde las imágenes falsas se vuelve inentendible porque StyleGAN2-ADA altera el contenido, finalmente, se entrena un modelo de aprendizaje profundo basado en capas de convolución para clasificar imágenes como reales o falsas; los autores describen una arquitectura de varias capas y mencionan el uso de transformaciones de entrenamiento para mejorar la capacidad de generalizar.

Los autores refuerza la pertinencia de pasar de una decisión global (real/falso) a una localización espacial mediante máscara, además, al remarcar que ciertos enfoques requieren la imagen original y que, en su ausencia, disminuye la precisión, indica que un sistema debería de operar sin referencia, apoyándose en huellas internas del contenido.

1.5. The Cat and Mouse Game: The Ongoing Arms Race Between Diffusion Models and Detection Methods

Los autores [5] presentan una revisión sobre la carrera armamentista entre la generación de imágenes mediante modelos de difusión y las técnicas de detección, y organizan el campo mediante una taxonomía de enfoques: análisis en dominio de frecuencia (p. ej., métodos basados en Fourier y en wavelets), análisis en dominio espacial (estadísticas locales, patrones de ruido y artefactos a nivel píxel), métodos de detección basados en aprendizaje profundo (redes convolucionales, transformadores de visión y detectores multimodales) y enfoques híbridos que combinan señales espaciales y frecuenciales; además, incorporan el rol de conjuntos de datos y bancos de prueba, así como implicaciones y aplicaciones relacionadas con desinformación, derechos de autor y análisis forense.

Se discuten desafíos centrales que explican por qué la detección es un problema en evolución constante: los detectores suelen fallar al generalizar entre distintos modelos de difusión por la presencia de huellas específicas de cada generador, y también pierden desempeño ante transformaciones comunes en escenarios reales como compresión y redimensionamiento; adicionalmente, se subraya el caso de contenido mixto (elementos reales y sintéticos dentro de una misma imagen, como en tareas de relleno o secciones manipuladas), donde métodos globales pueden pasar por alto alteraciones locales y se requiere evaluar y diseñar métodos con capacidad de operar a nivel más fino, apoyados por conjuntos de datos más diversos que contemplen condiciones de uso real y protocolos de evaluación comparables.

Los autores señalan que en imágenes con contenido real y sintético mezclado es necesario distinguir componentes reales y generados dentro de la misma imagen, y proponen que esto

se evalúe a nivel píxel, además de mencionar que se investigan técnicas de localización con supervisión débil para abordar este escenario; también enfatizan que los detectores deben ser robustos a compresión y reescalado (degradaciones comunes en redes sociales) y capaces de generalizar a modelos no vistos.

Referencias

- [1] L. Deng, B. Wu, and J. Wang, “A multi-label classification method combined with texture enhancement for deepfake face detection,” *Multimedia Systems*, vol. 31, p. 410, 2025.
- [2] J. M. Yagual Castillo, “Desarrollo de una aplicación web con machine learning para la detección de deepfakes en casos de suplantación de identidad digital,” 2024.
- [3] M. R. Tiwari and S. S. Patil, “Deepfake image detection: A review of existing methods and a hybrid cnn-based proposed framework,” in *ICATCICT 2025*, vol. 341 of *EPJ Web of Conferences*, p. 01043, EDP Sciences, 2025.
- [4] S. Mashhadani, W. H. Abdulsalam, W. A. Shukur, and M. S. H. Al-Tamimi, “Digital forensics method for fake images detection using gan algorithm based on watermarking technique and image content,” *Iraqi Journal of Science*, vol. 67, no. 1, p. 40, 2025.
- [5] L. Laurier, A. Giulietta, A. Octavia, and M. Cleti, “The cat and mouse game: The ongoing arms race between diffusion models and detection methods,” 2024.