



Instituto Politécnico Nacional
Escuela Superior de Ingeniería Mecánica y Eléctrica
Unidad Culhuacán

Propuestas Iniciales

Castillo Delgado Angel Ivan
Rojas Lozada Cuauhtli Emiliano

1. Título

- Detección y localización de manipulaciones faciales deepfakes mediante segmentación semántica basada en redes neuronales convolucionales.

2. Alcances

- El proyecto se enfoca exclusivamente al análisis del rostro. El modelo se entrenará para detectar inconsistencias en texturas, iluminación y bordes dentro del contexto facial.
- Salida de segmentación explicativa: se entrega una máscara binaria (alterado/no alterado) y una visualización (overlay) que resalta la región modificada; se busca una región aproximada (no necesariamente precisión extrema sobre los píxeles modificados, mas bien un acotamiento próximo de segmentación)
- Manipulaciones cubiertas (deepfake): se considera remplazo de rostros, recreación y generación completa, incluyendo escenarios donde se agrega un rostro adicional en el encuadre.
- Sin imagen de referencia en inferencia: el sistema estará diseñado para segmentar con una sola imagen, sin requerir comparación contra una “foto real” de la persona.
- Conjunto de datos propio: recopilación, curación y estandarización de un conjunto de datos y banco de pruebas con meta de 50,000 muestras, con variación de contexto, con partición entrenamiento/validación/prueba y etiquetado mediante máscara binaria (alterado/no alterado) limitada a la región facial para las manipulaciones cubiertas.

3. Limites

- Debido a la carga computacional que implica el uso del modelo U-Net como un segmentador y la complejidad de su arquitectura compuesta por varias capas convolucionales el sistema no está diseñado para procesamiento en tiempo real en dispositivos de borde (móviles/IoT), sino para análisis forense offline o en servidores con GPU dedicada.
- El desempeño del segmentador U-Net y la posterior detección pueden verse afectados significativamente en imágenes con baja resolución, compresión excesiva o condiciones de iluminación extrema (muy oscura o saturada), donde los artefactos de compresión pueden confundirse con artefactos de manipulación
- Validez condicionada al conjunto de entrenamiento: el desempeño del modelo depende de los contextos y condiciones representados en el dataset; puede degradarse en escenarios subrepresentados, especialmente cuando el rostro sea muy pequeño, parcialmente visible u ocurra en encuadres complejos.
- Generalización acotada a técnicas conocidas: el rendimiento puede degradarse frente a métodos de deepfake no representados durante el entrenamiento.
- Segmentación limitada al rostro: la detección se restringe a la región facial; no se promete localizar manipulación en cabello, cuello, cuerpo o fondo.
- Sin clasificación del tipo de manipulación: el sistema no identifica qué tipo de deepfake es; entrega únicamente máscara binaria y resaltado.

- Casos difíciles no garantizados: oclusión fuerte (mano, cubrebocas, lentes), movimiento, baja luz extrema, compresión severa o elementos sobrepuestos pueden aumentar falsos positivos o falsos negativos.